

Entregable 1: Fase de Análisis y modelado conceptual

Del microdato al indicador:

Diseño e implementación de una base de datos de indicadores del mercado laboral colombiano a partir de los microdatos de la GEIH para el Observatorio Laboral

Realizado por:

Lina Tatiana Bautista Parra

Jessica Alejandra Gil Tellez

Jorge Said Reza Diaz

Mariana Alejandra Ussa Vargas

Ingeniería de Datos

Universidad del Rosario

Agosto 2026

Links

Repositorio: <https://github.com/Linabautista/Proyecto-ingeniera-de-datos-.git>

Trello: <https://trello.com/b/EieneZJy/prubea>

1. Contextualización

La Gran Encuesta Integrada de Hogares (GEIH) del DANE es la fuente principal de información sobre el mercado laboral en Colombia y de ella salen las cifras de participación, ocupación, desempleo, informalidad e ingresos que sirven como instrumento para las decisiones de política pública en el país. Esto surge a partir de los microdatos mensuales, de los cuales cualquier persona, investigador o analista de datos puede acceder y estimarlos siguiendo la metodología de cada indicador. Sin embargo, esto también genera algunos problemas, ya que la encuesta entrega datos crudos más no los resultados y se pueden generar reprocesos y depender del procesamiento de la persona encargada.

Esta situación la vive continuamente el Observatorio Laboral de la facultad de economía de la Universidad del Rosario (LaboUR), especialmente los investigadores Carlos Bermudez y Julian Montañez quienes son los clientes directos de este proyecto. Ellos son responsables de estimar indicadores y análisis sobre empleo, desempleo, informalidad, ingresos laborales y brechas del mercado de trabajo con desagregaciones por territorio, sexo y edad a partir de la GEIH, adicionalmente, responden solicitudes internas de la facultad y a requerimientos externos de entidades que necesitan cifras específicas que las publicaciones oficiales no siempre entregan calculadas.

La GEIH se publica como microdatos mensuales segmentados en módulos (características generales, ocupados, desocupados, inactivos, entre otros) con un volumen elevado de registros por período y un diseño muestral que implica el uso de factores de expansión, para que las cifras representen a la población. Además la fuente a veces tiene modificaciones de nombres, códigos de variables entre periodos.

Adicionalmente, cada indicador se produce de forma manual y repetida, los investigadores descargan los archivos de cada mes, unen los módulos por las llaves de persona y hogar, armonizan las variables, aplican factores de expansión y agregan por territorio y tiempo. Este proceso se rehace desde cero en cada solicitud y depende del criterio individual de quien lo ejecute y por esto se identifican los siguientes problemas:

1. Duplicación de tareas: En cada solicitud se repite el mismo procedimiento por completo, descargar, unir por llaves, armonizar variables, expandir y agregar.
2. Tiempo elevado de respuesta: La ausencia de una base consolidada e histórica de los indicadores, genera que obtener una serie de un indicador pueda tomar un tiempo elevado, lo que limita la capacidad de responder con agilidad
3. Riesgo de inconsistencia metodológica: Como cada investigador reprocesa indicadores individualmente, dos personas pueden obtener cifras distintas para el mismo indicador.

2. Formulación del problema

El observatorio laboral no cuenta con una base de datos consolidada, histórica y consultable de indicadores del mercado laboral construida a partir de los microdatos de la GEIH. Por lo tanto, la obtención de indicadores desagregados es un proceso manual, lento, difícil de reproducir y expuesto a inconsistencias metodológicas, lo que limita la capacidad del equipo para responder de forma ágil y confiable a las solicitudes de información.

Por esta razón, el proyecto busca resolver esta necesidad mediante tres entregables. Primero, una base de datos relacional que consolide y estandarice el procesamiento de los microdatos, segundo, una base no relacional que administre los metadatos que cambien con el tiempo y finalmente un tablero que permita consultar los indicadores ya calculados sin necesidad de acceder al dato crudo.

En general, centralizar el procesamiento en una base de datos organizada por capas permite aplicar una sola vez la armonización de variables y los factores de expansión, así como, garantizar la reproducibilidad de las cifras, tener un historial de los periodos y versionar las revisiones retroactivas del DANE. Adicionalmente, el modelo dimensional, el control de calidad (medidas de precisión y banderas de confiabilidad) y la separación entre dato crudo y dato analítico reducen el error humano y liberan a los investigadores de tareas repetitivas para concentrarse en otras tareas y el análisis.

Esta situación no es exclusiva del observatorio, la literatura documenta que producir estadísticas a partir de registros y encuestas exige un enfoque distinto sobre cómo se procesan y gestionan los datos y no solo sobre cómo se analizan. Bakker, van Rooijen y van Toor (2014) documentan la

respuesta de Estadísticas de los Países Bajos al mismo problema, y fue la creación del System of Social Statistical Datasets, un sistema de registros y encuestas interconectadas y estandarizadas en el que convergen todos los procesos de producción de estadísticas sociales de la oficina, apoyándose en identificadores, en metadatos administrados de forma sistemática y de un proceso de estandarización previa, esto funcionó como una infraestructura compartida y orientada a productos para toda la producción de estadísticas sociales, en lugar de reprocesar las fuentes para cada estudio.

Además, tener información laboral oportuna y confiable es un insumo directo de las decisiones de política pública sobre empleo, informalidad y brechas de género, que afectan la vida de las personas. y al democratizar el acceso a indicadores rigurosos y comparables, el proyecto permite fortalecer la capacidad del observatorio y de las entidades que se apoyan en él para formular y evaluar políticas basadas en evidencia.

3. Objetivos

- **Objetivo General.**

Diseñar e implementar una solución de ingeniería de datos base de datos, compuesta por una base de datos relacional, una base de datos no relacional y un tablero de visualización que entregue indicadores del mercado laboral precalculados con periodicidad mensual y anual, desagregados por territorio, sexo, rango de edad y rama de actividad, de modo que el Observatorio Laboral pueda consultarlos de forma ágil, confiable y reproducible.

- **Objetivos Específicos.**

1. Construir el proceso de carga incremental e integración de los microdatos mensuales de la GEIH, uniendo los módulos por las llaves de persona y hogar y rechazando las cargas incompletas o inválidas.
2. Diseñar e implementar la armonización de las variables cuyos nombres y códigos cambian entre periodos, documentando sus equivalencias en un catálogo maestro que permita ampliar el rango temporal de la base.
3. Diseñar e implementar la base de datos relacional por capas con un modelo dimensional que almacene los indicadores aplicando los factores de expansión, con historización de los periodos y control de calidad mediante el coeficiente de variación.

4. Implementar una base de datos no relacional en MongoDB para administrar el diccionario de variables, las metodologías de cálculo y el registro de fuentes.
5. Desarrollar un tablero de visualización que permita filtrar, comparar y exportar los indicadores consumiendo únicamente las tablas agregadas de la base.
6. Validar la solución replicando indicadores oficiales publicados por el DANE para verificar la consistencia de las transformaciones.

4. Alcance

El proyecto se limita a la GEIH como única fuente de datos y a los indicadores principales del mercado laboral definidos por los investigadores del observatorio (tasa global de participación, tasa de ocupación, tasa de desempleo, informalidad, subempleo, ingresos laborales, horas trabajadas y calidad del empleo entendido como tipo de contrato y cotización a pensión). Los indicadores se entregan con periodicidad mensual y anual, con desagregación territorial y por variables demográficas (sexo, edad), respetando la representatividad estadística de cada combinación. Además, la carga inicial cubre los periodos comprendidos entre enero de 2024 y el último mes disponible de 2026. Sin embargo, el modelo debe permitir ampliar el rango tanto hacia adelante, incorporando periodos nuevos que el DANE publique, como hacia atrás, incorporando periodos anteriores a 2024, sin rediseñar la estructura de la base.

Delimitación técnica

Componente	Tecnología
Base de datos relacional	PostgreSQL
Base de datos no relacional	MongoDB (Mongo Shell, Compass y Node.js)
Procesamiento y carga	Python, con diseño orientado a objetos
Tablero de visualización	Power BI
Gestión del trabajo	Trello
Modelado y diagramas	draw.io
Control de versiones	GitHub, con una rama por integrante

Asimismo, el público objetivo de la solución son los investigadores del Observatorio Laboral como usuarios principales y el equipo de desarrollo como usuario administrador de las cargas.

Alcances excluidos

1. No se integran otras fuentes distintas a la GEIH (p. ej. ECV, ENPH o EMICRON).
2. No se incluyen proyecciones, pronósticos ni modelos predictivos.
3. El usuario final no accede a microdatos individuales, solamente a la información agregada.
4. No se ofrece desagregación por departamento ni por municipio o por otras variables demográficas no mencionadas anteriormente
5. No se garantiza la comparabilidad de periodos afectados por cambios metodológicos del rediseño cuando esta no sea posible estadísticamente.
6. No se automatiza la descarga de los archivos desde el portal del DANE


Posibles desarrollos futuros

1. Ampliación de la serie hacia períodos anteriores a 2024
2. Incorporación de una desagregaciones más amplia por departamento o otras condiciones como nivel educativo con periodicidad anual
3. Integración de otras encuestas del DANE para enriquecer el análisis.
4. Automatización de la descarga de los microdatos desde el DANE y exposición de los datos mediante una API.

5. Metodología de desarrollo.

El equipo adopta la metodología ágil Kanban para gestionar el flujo continuo de trabajo, apoyado en un tablero Trello. Se eligió Kanban porque el proyecto está dispuesto en entregables con fechas fijas y porque el tamaño del equipo hace innecesario el uso de metodologías más complejas. Esto se organiza en el aplicativo Trello que permite organizar las tareas y las Historias de Usuario por tarjetas y se organiza de la siguiente manera:

Columna	Qué contiene	Criterio de salida
Backlog	Todas las tarjetas derivadas de los requisitos y de las historias de usuario, priorizadas por el Product Owner.	La tarjeta tiene responsable y criterios de aceptación claros.
En curso	Tarjetas que alguien está trabajando activamente.	El trabajo está terminado según la tarjeta.
Revisión	Tarjetas terminadas a la espera de revisión por un integrante distinto de quien las hizo.	La responsable de calidad aprueba, o devuelve con comentarios.
Terminado	Tarjetas aprobadas e integradas en la rama principal del repositorio.	—



Adicionalmente, se definieron los siguientes roles en el equipo:

Integrante	Rol en el flujo de trabajo (Kanban)
Mariana Ussa	Facilitadora de flujo: mantiene el tablero de Trello, vigila el límite de trabajo en curso y gestiona los bloqueos.
Jessica Gil	Product Owner y contacto con el cliente: prioriza el backlog y valida los entregables con el observatorio.
Lina Bautista	Responsable de calidad: revisa las tarjetas en la columna de revisión antes de darlas por terminadas.
Jorge Reza	Integrador: responsable del repositorio, de las ramas individuales y de la integración entre módulos.

y un cronograma que se ajusta de acuerdo a las fechas de los entregables:

Fase	Inicio	Fin	Entregable
1. Análisis y modelado conceptual	Agosto de 2026	2 de septiembre de 2026	Entregable 1
2. Diseño y desarrollo relacional	3 de septiembre de 2026	Primera semana de octubre	Entregable 2
3. No relacional y visualización	Segunda semana de octubre	Segunda semana de noviembre	Entregable 3
4. Consolidación y pruebas	Tercera semana de noviembre	Última semana de noviembre	Entregable final

Igualmente se tiene la definición de tareas y el aporte de cada integrante del equipo para cada uno de los entregables:


Integrante	Entregable 1	Entregable 2	Entregable 3	Entregable final
Mariana	Requisitos de administración y trazabilidad; historias HU-04 y HU-05.	Tablas Usuario y Carga; disparadores de auditoría.	Colección de fuentes; consultas cruzadas.	Coordinación del plan de pruebas.
Jessica	Coordinación del documento; contexto, problema y objetivos; historias HU-01 a HU-03.	Tabla Microdato; procedimientos de carga.	Diccionario de variables; coordinación del tablero.	Documentación técnica.
Lina	Requisitos de indicadores y cálculos; historias HU-06 y HU-07.	Tablas Indicador y CalculoIndicador; vistas.	Colección de metodologías.	Réplica de indicadores oficiales.
Jorge	Modelado de dimensiones; historias HU-08 y HU-09; diagramas.	Tablas de dimensiones; consultas multitable.	Tablero en Power BI y exportación.	Integración del repositorio.

6. Propuesta de solución

El enfoque predominante en equipos de investigadores u observatorios consiste en procesar los archivos crudos de la encuesta mediante rutinas locales en Stata o en R, con paquetes que soportan diseños muestrales complejos. Este es un enfoque válido para un análisis puntual, pero no soluciona el problema de reprocesamiento, ya que cada indicador de estima desde cero, la memoria de la máquina limita el número de periodos que pueden manipularse a la vez y no existe una capa que varias personas puedan consultar de forma concurrente.


En el contexto nacional, Otero-Cortés et al. (2025) muestran el valor de la GEIH como sus límites, la encuesta es representativa a nivel nacional para zonas urbanas y rurales y para las principales ciudades y áreas metropolitanas, pero las muestras recolectadas a nivel municipal fuera de esas ciudades no son representativas y no todos los municipios se muestrean simultáneamente. Esta constatación es la que sustenta la delimitación territorial adoptada. De acuerdo con esto se muestran las alternativas de la solución con diagramas de flujo:

Alternativa 1. Rutina local en Stata o R




Alternativa 2. Arquitectura por capas con base de datos y tablero

Proceso de carga (se ejecuta una vez por período)



Proceso de consulta (se ejecuta en cada solicitud)



El usuario nunca accede al microdato individual: el tablero consume únicamente la capa analítica. La armonización y la expansión ya fueron aplicadas una sola vez durante la carga.

Además se presenta una tabla comparativa de ambas alternativas.

Criterio	Alternativa 1	Alternativa 2 (seleccionada)
Reutilización del procesamiento	Nula: cada indicador se recalcula desde cero.	Total: la armonización y la expansión se aplican una vez.

Criterio	Alternativa 1	Alternativa 2 (seleccionada)
Reproducibilidad	Depende del guión y del criterio de quien lo ejecuta.	Garantizada por la trazabilidad de cargas y el versionado.
Tiempo de respuesta	Días, por la preparación manual de cada serie.	Segundos, sobre tablas agregadas.
Acceso concurrente	No: cada quien trabaja sobre su copia local.	Sí: varios usuarios consultan el mismo tablero.
Control de calidad	Manual y no sistemático.	Automático, con coeficiente de variación y banderas.
Costo	Bajo inicial, alto acumulado en horas.	Medio inicial, bajo acumulado.
Curva de aprendizaje	Baja.	Media.
Ajuste al curso	No cubre bases de datos ni visualización.	Cubre relacional, no relacional y tablero.

De acuerdo a lo anterior, se selecciona la alternativa 2, ya que lo más importante no es el rendimiento sino la reproducibilidad, ya que el problema que el cliente describe es que en algunos casos el indicador puede dar distinto según quién lo calcule y eso se resuelve fijando el procesamiento en un lugar único y auditable. Igualmente, el rendimiento y el acceso concurrente son consecuencias favorables de esa decisión. Y la alternativa 1 se descarta porque reproduce el problema que se quiere resolver.

7. Requisitos del sistema

Requisitos Funcionales (RQF) de alto nivel.

Código	Requisito de alto nivel
RQF-AL-01	El sistema debe administrar los usuarios y registrar la trazabilidad de todas las cargas.

Código	Requisito de alto nivel
RQF-AL-02	El sistema debe ingerir y armonizar los microdatos mensuales de la GEIH.
RQF-AL-03	El sistema debe calcular y almacenar los indicadores ponderados con su medida de precisión.
RQF-AL-04	El sistema debe administrar las dimensiones de análisis y permitir la consulta de los indicadores.
RQF-AL-05	El sistema debe administrar en una base no relacional el diccionario de variables, las metodologías y las fuentes.

Requisitos Funcionales (RQF) de bajo nivel.

Código	Requisito	Usuario
RQF-001	El sistema debe registrar los usuarios con su rol y sus credenciales de acceso.	Administrador
RQF-002	El sistema debe autenticar al usuario antes de permitir operaciones de carga o administración.	Administrador
RQF-003	El sistema debe restringir las operaciones de administración a los usuarios autorizados.	Administrador
RQF-004	El sistema debe registrar cada carga con su fecha, su usuario responsable y su periodo procesado.	Ingeniero de datos
RQF-005	El sistema debe registrar el estado de cada carga como exitosa, rechazada o parcial.	Ingeniero de datos
RQF-006	El sistema debe impedir que un mismo periodo se cargue dos veces.	Ingeniero de datos

Código	Requisito	Usuario
RQF-007	El sistema debe registrar en una tabla de auditoría los registros sin correspondencia entre módulos.	Ingeniero de datos
RQF-008	El sistema debe generar un registro de eventos al finalizar cada carga con los datos procesados y rechazados.	Ingeniero de datos
RQF-009	El sistema debe versionar las revisiones retroactivas del DANE sin sobrescribir la carga anterior.	Ingeniero de datos
RQF-010	El sistema debe impedir la modificación directa de los datos analíticos sin dejar registro de auditoría.	Administrador
RQF-011	El sistema debe cargar los microdatos mensuales de la GEIH desde los archivos por módulo publicados por el DANE.	Ingeniero de datos
RQF-012	El sistema debe unir los módulos de cada periodo mediante las llaves DIRECTORIO, SECUENCIA_P y ORDEN.	Ingeniero de datos
RQF-013	El sistema debe ejecutar cargas incrementales procesando únicamente los periodos nuevos.	Ingeniero de datos
RQF-014	El sistema debe verificar que el periodo contenga todos los módulos requeridos antes de iniciar la carga.	Ingeniero de datos
RQF-015	El sistema debe rechazar los archivos con estructura de columnas o codificación inválida.	Ingeniero de datos
RQF-016	El sistema debe conservar los microdatos originales sin transformar en la capa cruda.	Ingeniero de datos
RQF-017	El sistema debe armonizar los nombres y códigos de las variables que cambian entre periodos hacia un estándar único.	Ingeniero de datos

Código	Requisito	Usuario
RQF-018	El sistema debe mantener una tabla maestra de equivalencias de variables por periodo.	Ingeniero de datos
RQF-019	El sistema debe marcar las variables cuya equivalencia no esté registrada en la tabla maestra.	Ingeniero de datos
RQF-020	El sistema debe permitir ampliar el rango de periodos cargados hacia adelante y hacia atrás sin rediseñar el modelo.	Ingeniero de datos
RQF-021	El sistema debe clasificar la población en edad de trabajar aplicando el umbral de quince años y más.	Ingeniero de datos
RQF-022	El sistema debe clasificar la población económicamente activa en ocupados y desocupados.	Ingeniero de datos
RQF-023	El sistema debe aplicar los factores de expansión FEX_C publicados por el DANE a cada registro.	Ingeniero de datos
RQF-024	El sistema debe calcular la tasa global de participación, la tasa de ocupación y la tasa de desempleo.	Investigador
RQF-025	El sistema debe calcular la proporción de informalidad según la cotización a seguridad social.	Investigador
RQF-026	El sistema debe calcular el subempleo, las horas trabajadas y el ingreso laboral promedio.	Investigador
RQF-027	El sistema debe calcular el coeficiente de variación de cada indicador estimado.	Investigador
RQF-028	El sistema debe asignar una bandera de baja confiabilidad a los indicadores cuyo coeficiente de variación supere el umbral definido.	Investigador
RQF-029	El sistema debe almacenar cada cálculo de indicador asociado a su combinación de dimensiones.	Ingeniero de datos

Código	Requisito	Usuario
RQF-030	El sistema debe registrar la definición, la fórmula y las variables fuente de cada indicador en el catálogo de metodologías.	Investigador
RQF-031	El sistema debe mantener el catálogo de periodos con periodicidad mensual y anual.	Ingeniero de datos
RQF-032	El sistema debe mantener el catálogo de territorios en los niveles definidos en el alcance.	Ingeniero de datos
RQF-033	El sistema debe estandarizar los códigos territoriales según la división político-administrativa DIVIPOLA.	Ingeniero de datos
RQF-034	El sistema debe clasificar la edad en los rangos 15-17, 18-28, 29-44, 45-59 y 60 o más.	Ingeniero de datos
RQF-035	El sistema debe estandarizar las ramas de actividad económica según la clasificación CIIU.	Ingeniero de datos
RQF-036	El sistema debe permitir filtrar los indicadores por periodo, territorio, sexo, rango de edad y rama de actividad.	Investigador
RQF-037	El sistema debe permitir comparar dos o más indicadores mediante gráficos o tablas.	Investigador
RQF-038	El sistema debe mostrar un mensaje informativo cuando no existan datos para la combinación de filtros seleccionada.	Investigador
RQF-039	El sistema debe permitir exportar los resultados consultados en formatos CSV, Excel y JSON.	Investigador
RQF-040	El sistema debe entregar los indicadores al tablero sin exponer los microdatos individuales.	Investigador

Requisitos No Funcionales.

Código	Categoría	Requisito
RNF-01	Rendimiento	Las consultas sobre las tablas agregadas deben responder en menos de tres segundos para el 95 % de las solicitudes.
RNF-02	Escalabilidad	La incorporación de nuevos periodos debe realizarse de forma incremental, sin degradación apreciable del tiempo de consulta ni rediseño del modelo.
RNF-03	Seguridad y privacidad	El sistema no debe exponer datos a nivel de registro individual ni permitir la reidentificación de personas encuestadas.
RNF-04	Reproducibilidad	Dos ejecuciones sobre el mismo conjunto de archivos fuente deben producir resultados numéricos idénticos.
RNF-05	Trazabilidad	Toda carga y toda modificación de datos analíticos deben quedar registradas con usuario, fecha y periodo afectado.
RNF-06	Usabilidad	El tablero debe permitir consultar y exportar indicadores sin requerir conocimientos de SQL.
RNF-07	Mantenibilidad	El código debe organizarse en clases con responsabilidad única, de modo que un cambio en la fuente afecte a una sola clase.
RNF-08	Licenciamiento	La solución debe apoyarse en herramientas gratuitas o cubiertas por la licencia académica de la universidad.

Historias de Usuario.

HU-01 · Carga de microdatos GEIH

Módulo: M2 **Requisitos asociados:** RQF-011, RQF-013, RQF-014, RQF-015

Como ingeniero de datos, **quiero** que el sistema cargue los microdatos mensuales de la GEIH desde los archivos por módulo publicados por el DANE, **para** que la información quede disponible como insumo para construir los indicadores del mercado laboral.

Criterios de aceptación:

- El sistema carga todos los módulos del periodo y los guarda en la capa cruda.
- No se puede cargar un periodo si falta alguno de sus módulos.
- No se carga un mismo periodo dos veces.
- Los archivos con estructura o codificación inválida son rechazados.
- En cada ejecución se procesan únicamente los periodos nuevos.

HU-02 · Unión de módulos

Módulo: M2 **Requisitos asociados:** RQF-012, RQF-007

Como ingeniero de datos, **quiero** que el sistema una automáticamente los módulos de cada periodo mediante las llaves de persona y hogar, **para** que cada persona quede con toda su información integrada en un solo registro por periodo.

Criterios de aceptación:

- El sistema une los módulos usando DIRECTORIO, SECUENCIA_P y ORDEN.
- Cada persona queda en un único registro por periodo, sin duplicados.
- No se mezclan registros de periodos distintos.
- Los registros sin correspondencia entre módulos se marcan y se reportan.

HU-03 · Armonización de variables

Módulo: M2 **Requisitos asociados:** RQF-017, RQF-018, RQF-019

Como ingeniero de datos, **quiero** que el sistema armonice los nombres y códigos de las variables que cambian entre periodos hacia un estándar único, **para** que una misma variable pueda compararse a lo largo del tiempo sin ambigüedad.

Criterios de aceptación:

- Cada variable equivalente queda con un solo nombre y código estándar en toda la serie.
- Una misma variable no aparece con nombres distintos según el periodo.
- Las categorías o códigos de una variable son consistentes entre periodos.
- Cada variable estandarizada queda documentada con su equivalencia por periodo.
- Si llega una variable sin equivalencia definida, el sistema la marca y la reporta.

HU-04 · Trazabilidad de las cargas

Módulo: M1 **Requisitos asociados:** RQF-004, RQF-005, RQF-008, RQF-009

Como ingeniero de datos, **quiero** que el sistema registre la fecha, el usuario y el periodo de cada carga realizada, **para** poder reproducir cualquier cifra publicada y saber con qué versión de los datos fue calculada.

Criterios de aceptación:

- Cada carga queda registrada con fecha, usuario responsable y periodo procesado.
- El estado de la carga se registra como exitosa, rechazada o parcial.
- Al finalizar la carga se genera un registro de eventos con los datos procesados y rechazados.
- Una revisión retroactiva del DANE genera una versión nueva sin borrar la anterior.

HU-05 · Control de acceso

Módulo: M1 **Requisitos asociados:** RQF-001, RQF-002, RQF-003, RQF-010

Como administrador del sistema, **quiero** que el sistema restrinja las operaciones de carga y administración a los usuarios autorizados, **para** evitar modificaciones no controladas sobre los datos analíticos.

Criterios de aceptación:

- El usuario debe autenticarse antes de ejecutar una carga o una operación de administración.
- Cada usuario tiene un rol asociado que determina qué operaciones puede ejecutar.

- Un usuario no autorizado no puede administrar indicadores ni fuentes.
- Ninguna modificación de datos analíticos ocurre sin quedar registrada.

HU-06 · Cálculo de indicadores ponderados

Módulo: M3 **Requisitos asociados:** RQF-021 a RQF-026, RQF-029

Como investigador del observatorio, **quiero** que el sistema calcule los indicadores aplicando automáticamente los factores de expansión, **para** que las cifras representen a la población y no a la muestra.

Criterios de aceptación:

- El sistema aplica el factor de expansión FEX_C a cada registro antes de agregar.
- La población en edad de trabajar se clasifica con el umbral de quince años y más.
- La población económicamente activa se divide en ocupados y desocupados.
- Cada cálculo queda almacenado asociado a su combinación de dimensiones.
- Los registros sin factor de expansión se reportan y no se incluyen en el cálculo.

HU-07 · Control de calidad estadística

Módulo: M3 **Requisitos asociados:** RQF-027, RQF-028

Como investigador del observatorio, **quiero** que el sistema calcule el coeficiente de variación de cada indicador y marque los poco confiables, **para** no publicar cifras cuya precisión muestral sea insuficiente.

Criterios de aceptación:

- Cada indicador almacenado tiene su coeficiente de variación calculado.
- Los indicadores que superan el umbral definido quedan con bandera de baja confiabilidad.
- El tablero muestra la bandera junto a la cifra correspondiente.
- El umbral aplicado queda documentado en el catálogo de metodologías.

HU-08 · Filtrado y comparación de indicadores

Módulo: M4 **Requisitos asociados:** RQF-036, RQF-037, RQF-038

Como investigador o analista, **quiero** filtrar y comparar los indicadores por periodo, territorio, sexo, rango de edad y rama de actividad, **para** identificar diferencias entre grupos de población y su evolución en el tiempo.

Criterios de aceptación:

- El tablero ofrece filtros por las cinco dimensiones definidas.
- Los filtros se aplican de forma simultánea y actualizan los resultados.
- El usuario puede seleccionar dos o más indicadores para compararlos.
- Si no hay datos para la combinación elegida, se muestra un mensaje informativo.
- Los filtros pueden restablecerse al estado inicial.

HU-09 · Exportación de resultados

Módulo: M4 **Requisitos asociados:** RQF-039, RQF-040

Como investigador o analista, **quiero** descargar la información consultada en CSV, Excel o JSON, **para** usar los datos en herramientas externas de análisis.


Criterios de aceptación:

- El usuario selecciona el formato de descarga.
- El archivo descargado conserva los datos consultados con sus encabezados.
- La exportación entrega únicamente información agregada.
- El sistema confirma cuando la descarga finaliza correctamente.

8. Modelado de la solución

Diagrama de Clases general del sistema.

El sistema se concibe bajo el paradigma orientado a objetos. Cada clase encapsula una responsabilidad del proceso y expone su comportamiento a través de métodos, de modo que un cambio en la fuente de datos se absorbe en una sola clase.



Interpretación:

La clase Usuario está compuesta por los atributos idUsuario, nombreUsuario, correoUsuario, rolUsuario, contraseñaUsuario y estadoUsuario, donde el atributo clave es idUsuario. También cuenta con las operaciones registrarUsuario, autenticarUsuario, consultarUsuario, modificarUsuario e inactivarUsuario

La clase Carga está compuesta por los atributos idCarga, fechaCarga, periodoCarga, estadoCarga, versionCarga, registrosProcesadosCarga y registrosRechazadosCarga, donde el atributo clave es idCarga. Cuenta con las operaciones iniciarCarga, validarCarga, registrarCarga, consultarCarga y anularCarga. El atributo versionCarga es el que permite incorporar las revisiones retroactivas del DANE sin sobrescribir la carga anterior.

La clase Microdato está compuesta por los atributos idMicrodato, directorioMicrodato, secuenciaMicrodato, ordenMicrodato, factorExpansionMicrodato, condicionActividadMicrodato, ingresoLaboralMicrodato y horasTrabajadasMicrodato, donde el atributo clave es idMicrodato. Cuenta con las operaciones unirModulosMicrodato, armonizarMicrodato, validarMicrodato y consultarMicrodato. Los atributos directorioMicrodato, secuenciaMicrodato y ordenMicrodato corresponden a las llaves de hogar y persona con las que se unen los módulos de la encuesta.

La clase Indicador está compuesta por los atributos idIndicador, nombreIndicador, definicionIndicador, formulaIndicador, unidadIndicador y variablesFuenteIndicador, donde el

atributo clave es idIndicador. Cuenta con las operaciones registrarIndicador, calcularIndicador, consultarIndicador y modificarIndicador. Esta clase almacena la definición de la métrica, no su valor.

La clase CalculoIndicador está compuesta por los atributos consecutivoCalculoIndicador, valorCalculoIndicador, poblacionExpandidaCalculoIndicador, coeficienteVariacionCalculoIndicador y banderaConfiabilidadCalculoIndicador, donde el atributo clave parcial es consecutivoCalculoIndicador. Cuenta con las operaciones calcularValorCalculoIndicador, evaluarCalidadCalculoIndicador, consultarCalculoIndicador y exportarCalculoIndicador. Es una clase débil: su identificación depende de Microdato y de Indicador, y por sí sola no tiene existencia en el modelo.

Las clases de dimensión completan el modelo. Periodo está compuesta por idPeriodo, anioPeriodo, mesPeriodo, periodicidadPeriodo y marcoMuestralPeriodo, con clave idPeriodo. Territorio está compuesta por idTerritorio, nombreTerritorio, nivelTerritorio y codigoDivipolaTerritorio, con clave idTerritorio. Sexo está compuesta por idSexo, nombreSexo y codigoSexo, con clave idSexo. RangoEdad está compuesta por idRangoEdad, nombreRangoEdad, edadInicialRangoEdad y edadFinalRangoEdad, con clave idRangoEdad, y su atributo edadFinalRangoEdad es nulo en el rango de 60 años o más por tratarse de un intervalo abierto. Rama está compuesta por idRama, nombreRama, codigoCiiuRama y seccionRama, con clave idRama. Las cinco cuentan con las operaciones de registro y consulta de su respectivo catálogo, y RangoEdad añade clasificarRangoEdad para asignar cada registro a su intervalo.

Las clases se relacionan mediante asociación de la siguiente forma. Un usuario puede realizar varias o ninguna carga, y una carga debe tener exactamente un usuario asociado. Una carga produce una o varias filas de microdato, y un microdato pertenece a una única carga. Un microdato participa en varios cálculos de indicador y un indicador se calcula a partir de varios microdatos. Cada cálculo de indicador debe estar asociado a exactamente un periodo, un territorio, un sexo, un rango de edad y una rama de actividad, mientras que cada valor de dimensión puede aparecer en varios cálculos o en ninguno.

Selección módulos por integrante.

La solución se divide en 4 módulos, uno por integrante. La participación se realizó por agrupación de clases que tienen el mismo objetivo, de modo que cada módulo es coherente con las clases del diagrama de clases.

M1 agrupa Usuario y Carga, y responde por el acceso, el registro de cada ejecución y el versionado de las revisiones del DANE. M2 se organiza alrededor de Microdato: lectura de archivos, unión por llaves de hogar y persona, armonización y validación. M3 agrupa Indicador y CalculoIndicador, y concentra las reglas de negocio, los factores de expansión y el control de precisión. M4 agrupa las cinco dimensiones y el tablero que las consume, ya que los filtros disponibles para el usuario final son exactamente las dimensiones del catálogo.

Módulo	Responsable	Clases del modelo de datos	Alcance
M1 · Administración y trazabilidad	Mariana	Usuario, Carga	Usuarios y permisos, registro de cargas, auditoría y versión de revisiones del DANE.
M2 · Ingesta y armonización	Jessica	Microdato	Lectura de archivos, unión por llaves de persona y hogar, armonización y validación.
M3 · Indicadores	Lina	Indicador, CalculoIndicador	Clasificación PET y PEA, factores de expansión, coeficiente de variación y catálogo de metodologías.
M4 · Dimensiones y consulta	Jorge	Periodo, Territorio, Sexo, RangoEdad, Rama	Catálogos de dimensiones, DIVIPOLA, CIIU y tablero de consulta en Power BI.

Mapa de Stakeholders.

Los actores del proyecto se clasifican según su nivel de influencia y su nivel de interés siguiendo la matriz de Mendelow. En el cuadrante de alta influencia y alto interés se ubican los investigadores del Observatorio Laboral, que son el cliente y definen los requisitos, y el docente

del curso, que evalúa los entregables; ambos exigen administración cercana y validación continua. El DANE se sitúa en alta influencia y bajo interés: no participa del desarrollo, pero cualquier cambio en su metodología o en su calendario de publicación condiciona el sistema, por lo que la estrategia consiste en seguir fielmente sus definiciones. En el cuadrante de bajo poder y alto interés están el Ministerio del Trabajo, el Departamento Nacional de Planeación, el Banco de la República y el SENA, entidades que consumirían los indicadores sin intervenir en su construcción y a las que corresponde mantener informadas. Finalmente, la ciudadanía se ubica en bajo poder y bajo interés directo, aunque es la beneficiaria última de las decisiones de política que se apoyan en estas cifras.





Diagrama de Clases específico de modelo de datos relacional (MER).

A diferencia del diagrama general, este modelo recoge únicamente las entidades que persisten, con sus atributos y sus multiplicidades, sin lógica de proceso.

Las entidades fuertes del modelo son Carga, Microdato, Indicador y las cinco dimensiones (Periodo, Territorio, Sexo, RangoEdad y Rama), cada una con existencia propia y clave primaria propia. Como la relación entre Microdato e Indicador es de muchos a muchos, un mismo registro alimenta varios indicadores y cada indicador se calcula a partir de muchos registros. Las reglas de normalización no admiten dejar esa cardinalidad en el modelo, y además no habría dónde almacenar los datos que pertenecen a la relación y no a ninguna de las dos entidades por lo que se introduce entonces la entidad débil CalculoIndicador, que descompone esa relación en dos relaciones identificadoras de uno a muchos. Así, cada instancia se asocia además a exactamente un valor de cada dimensión, mientras que cada valor de dimensión puede aparecer en muchos cálculos o en ninguno. Esa convergencia es la que permite que el tablero recupere cualquier cifra a partir de una combinación de filtros.




Modelo conceptual entidad-relación (ER).

El modelo conceptual traduce las clases anteriores a entidades y relaciones con sus cardinalidades. La relación entre Microdato e Indicador es de muchos a muchos, ya que un mismo registro alimenta varios indicadores y un indicador se calcula a partir de muchos registros. Siguiendo las reglas de normalización, esa relación se resuelve mediante la entidad

débil CalculoIndicador, cuya existencia depende de las entidades que la identifican y que almacena el valor calculado junto con su medida de precisión.

Entidad	Tipo	Relación principal
Carga	Fuerte	Un usuario realiza muchas cargas; una carga produce muchos microdatos.
Microdato	Fuerte	Participa en la relación identificadora con CalculoIndicador.
CalculoIndicador	Débil	Identificada por Microdato e Indicador; se relaciona con las cinco dimensiones.
Indicador	Fuerte	Participa en la relación identificadora con CalculoIndicador.
Periodo, Territorio, Sexo, RangoEdad, Rama	Fuertes	Cada una se relaciona uno a muchos con CalculoIndicador.

Link: <https://app.chartdb.io/invite/86e6373889974023942c0f>



Diccionarios de datos de las tablas

Tabla: usuario

Fecha: 02/09/2026

Descripción: Tabla que contiene la información de los usuarios autorizados en el sistema.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_usuario	int / uuid	—	Primary Key	Llave primaria correspondiente al usuario
nombre_usuario	varchar	100	Not null	Nombre completo del usuario
correo_electronico	varchar	150	Not null, Unique	Correo institucional o de contacto

rol_usuario	varchar	50	Not null	Rol asignado (ej. Administrador, Analista)
-------------	---------	----	----------	--

Tabla: carga

Fecha: 02/09/2026

Descripción: Tabla que contiene el registro de ejecuciones de ingesta de microdatos.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_carga	int / uuid	—	Primary Key	Llave primaria correspondiente a la carga
id_usuario	int / uuid	—	Foreign Key, Not null	Identificador del usuario que realizó la carga
fecha_carga	timestamp	—	Not null	Fecha y hora de ejecución
periodo_cargado	varchar	7	Not null	Período de datos procesados (YYYY-MM)
estado_carga	varchar	20	Not null	Estado del proceso (Exitosa, Fallida, etc.)

Tabla: microdato

Fecha: 01/09/2026

Descripción: Tabla que almacena los registros individuales estandarizados de la GEIH-DANE.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_microdato	bigint	—	Primary Key	Llave primaria correspondiente al registro individual

id_carga	int / uuid	—	Foreign Key, Not null	Identificador del lote de carga origen
directorío	varchar	20	Not null	Llave de vivienda/hogar según DANE
secuencia_p	varchar	10	Not null	Secuencia del hogar dentro de la vivienda
orden	varchar	10	Not null	Número de orden de la persona
fex_c	numeric	12,4	Not null	Factor de expansión poblacional provisto por DANE

Tabla: indicador

Fecha: 01/09/2026

Descripción: Catálogo maestro de indicadores de mercado laboral.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_indicador	int	—	Primary Key	Llave primaria correspondiente al indicador
nombre_indicador	varchar	100	Not null	Nombre descriptivo del indicador
codigo_indicador	varchar	20	Not null, Unique	Código estandarizado del indicador
formula_metodologica	text	—	null	Expresión matemática o algoritmo de cálculo
estado_activo	boolean	—	Not null	Estado del indicador (True = Activo, False = Inactivo)

Tabla: periodo

Fecha: 01/09/2026

Descripción: Tabla de dimensión para la segmentación temporal.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_periodo	int	—	Primary Key	Llave primaria correspondiente al período
anio	int	—	Not null	Año de referencia
mes	int	—	Not null	Mes del año (1-12)
trimestre	int	—	Not null	Trimestre del año (1-4)

Tabla: territorio

Fecha: 01/09/2026

Descripción: Tabla de dimensión para la ubicación geográfica.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_territorio	int	—	Primary Key	Llave primaria correspondiente al territorio
codigo_departamento	varchar	5	Not null	Código DIVIPOLA del departamento
nombre_departamento	varchar	100	Not null	Nombre del departamento
area_metropolitana	varchar	100	null	Área metropolitana correspondiente

Tabla: sexo

Fecha: 01/09/2026

Descripción: Tabla de dimensión para la clasificación por sexo.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_sexo	int	—	Primary Key	Llave primaria correspondiente al sexo
descripcion	varchar	20	Not null	Categoría (Hombre, Mujer, etc.)

Tabla: rango edad

Fecha: 01/09/2026

Descripción: Tabla de dimensión para la agrupación etaria.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_rangoedad	int	—	Primary Key	Llave primaria correspondiente al rango de edad
rango_minimo	int	—	Not null	Edad mínima en años
rango_maximo	int	—	Not null	Edad máxima en años
etiqueta_rango	varchar	50	Not null	Etiqueta descriptiva del rango

Tabla: rama

Fecha: 01/09/2026

Descripción: Tabla de dimensión para sectores de actividad económica.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_rama	int	—	Primary Key	Llave primaria correspondiente a la rama
codigo_ciiu	varchar	10	Not null	Código de clasificación CIIU
descripcion_ram a	varchar	150	Not null	Descripción del sector productivo

Tabla: calculo indicador

Fecha: 01/09/2026

Descripción: Entidad débil de hechos que almacena los resultados calculados y medidas de precisión.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
id_microdato	bigint	—	Primary Key, Foreign Key	Identificador del microdato origen
id_indicador	int	—	Primary Key, Foreign Key	Identificador del indicador calculado
id_periodo	int	—	Primary Key, Foreign Key	Identificador del período temporal
id_territorio	int	—	Primary Key, Foreign Key	Identificador de la ubicación geográfica
idsexo	int	—	Primary Key, Foreign Key	Identificador de la categoría de sexo
id_rangoedad	int	—	Primary Key, Foreign Key	Identificador del rango de edad

id_rama	int	—	Primary Key, Foreign Key	Identificador del sector económico
valor_calculado	numeric	15,4	Not null	Valor de la métrica calculada
medida_precision	numeric	8,4	null	Valor del Coeficiente de Variación (CV %)
flag_confiabilidad	boolean	—	Not null	Indicador de confiabilidad estadística del cálculo

9. Riesgos y mitigación

Riesgo	Impacto	Mitigación
El DANE modifica nombres o códigos de variables en una entrega nueva.	Alto	Catálogo maestro de equivalencias y marcado automático de variables sin correspondencia (RQF-018, RQF-019).
El DANE publica una revisión retroactiva de un periodo ya cargado.	Medio	Versionado de cargas sin sobrescritura (RQF-009).
Una combinación de filtros produce una estimación imprecisa.	Medio	Cálculo del coeficiente de variación y bandera de baja confiabilidad (RQF-027, RQF-028).
Los indicadores calculados no coinciden con las cifras oficiales.	Alto	Fase 4 de validación mediante réplica de indicadores publicados por el DANE.
Concentración del conocimiento en un solo integrante por módulo.	Medio	Revisión cruzada obligatoria en la columna de revisión del tablero y ramas individuales en el repositorio.

10. Referencias

Bakker, B. F. M., van Rooijen, J., y van Toor, L. (2014). The system of social statistical datasets of Statistics Netherlands: An integral approach to the production of register-based social statistics. *Statistical Journal of the IAOS*, 30(4), 411-424. <https://doi.org/10.3233/SJI-140803>

Departamento Administrativo Nacional de Estadística. (2024). Gran Encuesta Integrada de Hogares (GEIH): metodología general y ficha metodológica. DANE.

Otero-Cortés, A. (coord.), Acosta, K., Arango, L. E., Aristizábal, D., Ávila, O., Becerra, O., Fernández, C., Flórez, L. A., Galvis, L. A., Grajales, A., Granda, C., Hamann, F., Jaramillo, J., Medina, C., Morales, J., Morales, A., Morales, L., Ospina, J. J., Posso, C., Pulido, J. D., Ramos, M., y Sarasti, A. (2025). Nueva evidencia sobre la informalidad laboral y empresarial en Colombia. *Ensayos sobre Política Económica (ESPE)*, 108. <https://doi.org/10.32468/espe108>