Entregable 2: Diseño y Desarrollo de la Base de Datos Relacional

Del microdato al indicador:
Diseño e implementación de una base de datos de indicadores del mercado laboral colombiano a partir de los microdatos de la GEIH para el Observatorio Laboral

Realizado por:

Lina Tatiana Bautista Parra

Jessica Alejandra Gil Tellez

Jorge Said Reza Diaz

Mariana Alejandra Ussa Vargas

Ingeniería de Datos

Universidad del Rosario

Agosto 2026

Links

Repositorio: https://github.com/Linabautista/Proyecto-ingeniera-de-datos-.git

Trello: https://trello.com/b/EieneZJy/prubea

1. Contextualización

La Gran Encuesta Integrada de Hogares (GEIH) del DANE es la fuente principal de información sobre el mercado laboral en Colombia y de ella salen las cifras de participación, ocupación, desempleo, informalidad e ingresos que sirven como instrumento para las decisiones de política pública en el país. Esto surge a partir de los microdatos mensuales, de los cuales cualquier persona, investigador o analista de datos puede acceder y estimarlos siguiendo la metodología de cada indicador. Sin embargo, esto también genera algunos problemas, ya que la encuesta entrega datos crudos más no los resultados y se pueden generar reprocesos y depender del procesamiento de la persona encargada.

Esta situación la vive continuamente el Observatorio Laboral de la facultad de economía de la Universidad del Rosario (LaboUR), especialmente los investigadores Carlos Bermudez y Julian Montañez quienes son los clientes directos de este proyecto. Ellos son responsables de estimar indicadores y análisis sobre empleo, desempleo, informalidad, ingresos laborales y brechas del mercado de trabajo con desagregaciones por territorio, sexo y edad a partir de la GEIH, adicionalmente, responden solicitudes internas de la facultad y a requerimientos externos de entidades que necesitan cifras especificas que las publicaciones oficiales no siempre entregan calculadas.

La GEIH se publica como microdatos mensuales segmentados en módulos (características generales, ocupados, desocupados, inactivos, entre otros) con un volumen elevado de registros por período y un diseño muestral que implica el uso de factores de expansión, para que las cifras representen a la población. Además la fuente suele tener modificaciones de nombres, códigos de variables entre periodos.

Adicionalmente, cada indicador se produce de forma manual y repetida, los investigadores descargan los archivos de cada mes, unen los módulos por las llaves de persona y hogar, armonizan las variables, aplican factores de expansión y agregan por territorio y tiempo. Este proceso se rehace desde cero en cada solicitud y depende del criterio individual de quien lo ejecute y por esto se identifican los siguientes problemas:

1. Duplicación de tareas: En cada solicitud se repite el mismo procedimiento por completo, descargar, unir por llaves, armonizar variables, expandir y agregar.
2. Tiempo elevado de respuesta: La ausencia de una base consolidada e histórica de los indicadores, genera que obtener una serie de un indicador pueda tomar un tiempo elevado, lo que limita la capacidad de responder con agilidad
3. Riesgo de inconsistencia metodológica: Como cada investigador reprocesa indicadores individualmente, dos personas pueden obtener cifras distintas para el mismo indicador.

2. Formulación del problema

El observatorio laboral no cuenta con una base de datos consolidada, histórica y consultable de indicadores del mercado laboral construida a partir de los microdatos de la GEIH. Por lo tanto, la obtención de indicadores desagregados es un proceso manual, lento, difícil de reproducir y expuesto a inconsistencias metodológicas, lo que limita la capacidad del equipo para responder de forma ágil y confiable a las solicitudes de información. Lo anterior nos lleva a la siguiente **pregunta problema:** ¿Cómo diseñar e implementar una base de datos relacional en MySQL que consolide los microdatos de la GEIH y almacene indicadores del mercado laboral calculados con factores de expansión, de modo que el Observatorio Laboral pueda consultarlos de forma ágil, confiable y reproducible sin reprocesar los datos en cada solicitud?

Por esta razón, el proyecto busca resolver esta necesidad mediante tres entregables. Primero, una base de datos relacional en MySQL que consolide y estandarice los microdatos y almacene los indicadores calculados, segundo, una base no relacional que administre los metadatos que cambien con el tiempo y finalmente un tablero que permita consultar los indicadores ya calculados sin necesidad de acceder al dato crudo.

En general, centralizar el procesamiento en una base de datos permite aplicar una sola vez la armonización de variables y los factores de expansión, así como, garantizar la reproducibilidad de las cifras, tener un historial auditado de los indicadores. Adicionalmente, el modelo en dos partes (microdato e indicadores), el control de calidad (coeficiente de variación y bandera de confiabilidad) y la separación entre el dato individual y el indicador agregado reducen el error

humano y liberan a los investigadores de tareas repetitivas para concentrarse en otras tareas y el análisis.

Esta situación no es exclusiva del observatorio, la literatura documenta que producir estadísticas a partir de registros y encuestas exige un enfoque distinto sobre cómo se procesan y gestionan los datos y no solo sobre cómo se analizan. Bakker, van Rooijen y van Toor (2014) documentan la respuesta de Estadísticas de los Países Bajos al mismo problema, y fue la creación del System of Social Statistical Datasets, un sistema de registros y encuestas interconectadas y estandarizadas en el que convergen todos los procesos de producción de estadísticas sociales de la oficina, apoyándose en identificadores, en metadatos administrados de forma sistemática y de un proceso de estandarización previa, esto funcionó como una infraestructura compartida y orientada a productos para toda la producción de estadísticas sociales, en lugar de reprocesar las fuentes para cada estudio.

Además, tener información laboral oportuna y confiable es un insumo directo de las decisiones de política pública sobre empleo, informalidad y brechas de género, que afectan la vida de las personas. y al democratizar el acceso a indicadores rigurosos y comparables, el proyecto permite fortalecer la capacidad del observatorio y de las entidades que se apoyan en él para formular y evaluar políticas basadas en evidencia.

3. Objetivos

- **Objetivo General.**

Diseñar e implementar una solución de base de datos, compuesta por una base de datos relacional en MySQL, una base de datos no relacional y un tablero de visualización que entregue indicadores del mercado laboral precalculados con periodicidad mensual y anual, desagregados por territorio, sexo, rango de edad y rama de actividad, de modo que el Observatorio Laboral pueda consultarlos de forma ágil, confiable y reproducible.

- **Objetivos Específicos.**

1. Preparar los microdatos mensuales de la GEIH mediante un cuaderno de Python en Google Colab que seleccione las bases y variables necesarias, las armonice, las estandarice y las verifique antes de cargarlas.

2. Diseñar e implementar en MySQL el modelo relacional en dos partes, una de microdato (persona, ocupado y desocupado) y otra de indicadores, con sus dimensiones, tipos de indicador y usuarios.
3. Implementar procedimientos almacenados que calculen los indicadores aplicando los factores de expansión, con control de calidad mediante el coeficiente de variación, y un disparador que audite los cambios sobre los indicadores.
4. Implementar una base de datos no relacional en MongoDB para administrar el diccionario de variables, las metodologías de cálculo y el registro de fuentes.
5. Desarrollar un tablero de visualización que permita filtrar, comparar y exportar los indicadores consumiendo únicamente las tablas agregadas de la base.
6. Validar la solución replicando indicadores oficiales publicados por el DANE para verificar la consistencia de las transformaciones.

4. Alcance

El proyecto se limita a la GEIH como única fuente de datos y a los indicadores principales del mercado laboral definidos por los investigadores del observatorio (población económicamente activa, tasa global de participación, tasa de ocupación, tasa de desocupación,Los indicadores se entregan con periodicidad mensual y anual, con desagregación por territorio (nacional, urbano, rural y las 13 ciudades de la GEIH) y por sexo, rango de edad (15-17, 18-28, 29-44, 45-59 y 60 o más) y rama de actividad, respetando la representatividad estadística de cada combinación. Además, la carga inicial cubre los periodos comprendidos entre enero de 2024 y el último mes disponible de 2026. Sin embargo, el modelo debe permitir ampliar el rango tanto hacia adelante, incorporando periodos nuevos que el DANE publique, como hacia atrás, incorporando periodos anteriores a 2024, sin rediseñar la estructura de la base.

Delimitación técnica

Componente	Tecnología
Base de datos relacional	MySQL
Base de datos no relacional	MongoDB (Mongo Shell, Compass y Node.js)

Componente	Tecnología
Procesamiento y carga	Python en Google Colab (selección de variables, armonización, estandarización y verificación)
Tablero de visualización	Power BI
Gestión del trabajo	Trello
Modelado y diagramas	draw.io
Control de versiones	GitHub, con una rama por integrante

Asimismo, el público objetivo de la solución son los investigadores del Observatorio Laboral como usuarios principales y el equipo de desarrollo como usuario administrador de las cargas.

Alcances excluidos

1. No se integran otras fuentes distintas a la GEIH (p. ej. ECV, ENPH o EMICRON).
2. No se incluyen proyecciones, pronósticos ni modelos predictivos.
3. El usuario final no accede a microdatos individuales, solamente a la información agregada.
4. No se ofrece desagregación por departamento ni por municipio o por otras variables demográficas no mencionadas anteriormente
5. No se garantiza la comparabilidad de periodos afectados por cambios metodológicos del rediseño cuando esta no sea posible estadísticamente.
6. No se automatiza la descarga de los archivos desde el portal del DANE

Posibles desarrollos futuros

1. Ampliación de la serie hacia períodos anteriores a 2024
2. Incorporación de una desagregaciones más amplia por departamento o otras condiciones como nivel educativo con periodicidad anual
3. Integración de otras encuestas del DANE para enriquecer el análisis.

4. Automatización de la descarga de los microdatos desde el DANE y exposición de los datos mediante una API.

Tiempos y costos

El proyecto se ejecuta en 16 semanas, entre agosto y noviembre de 2026, distribuidas en las cuatro fases del cronograma. Cada integrante dedica en promedio 2 horas semanales, es decir, 8 horas semanales para el equipo y 128 horas en total.

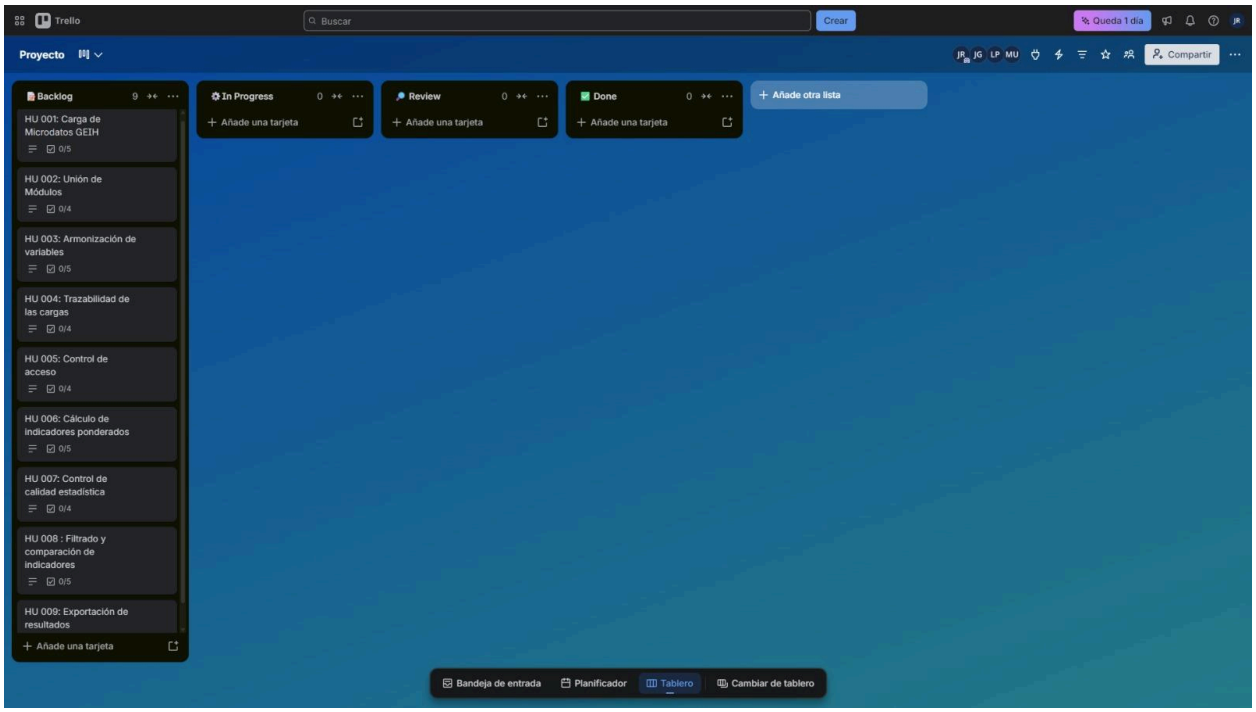
Los costos se estiman como el valor de las horas de trabajo del equipo. Como supuesto, la hora se valora con base en el salario mínimo legal mensual vigente de 2026 ($1.750.905) dividido en 210 horas mensuales, que corresponden a la jornada semanal de 42 horas, lo que da aproximadamente $8.338 por hora. Las herramientas del proyecto son gratuitas, por lo que no generan un costo adicional. Por lo tanto el costo total estimado es de $1.067.264 pesos colombianos. Sin embargo, este valor es una estimación con fines de planeación y no corresponde a pagos reales.

5. Metodología de desarrollo.

El equipo adopta la metodología ágil Kanban para gestionar el flujo continuo de trabajo, apoyado en un tablero Trello. Se eligió Kanban porque el proyecto está dispuesto en entregables con fechas fijas y porque el tamaño del equipo hace innecesario el uso de metodologías más complejas. Esto se organiza en el aplicativo Trello que permite organizar las tareas y las Historias de Usuario por tarjetas y se organiza de la siguiente manera:

Columna	Qué contiene	Criterio de salida
Backlog	Todas las tarjetas derivadas de los requisitos y de las historias de usuario, priorizadas por el Product Owner.	La tarjeta tiene responsable y criterios de aceptación claros.
En curso	Tarjetas que alguien está trabajando activamente.	El trabajo está terminado según la tarjeta.

Columna	Qué contiene	Criterio de salida
Revisión	Tarjetas terminadas a la espera de revisión por un integrante distinto de quien las hizo.	La responsable de calidad aprueba, o devuelve con comentarios.
Terminado	Tarjetas aprobadas e integradas en la rama principal del repositorio.	—



Adicionalmente, se definieron los siguientes roles en el equipo:

Integrante	Rol en el flujo de trabajo (Kanban)
Mariana Ussa	Facilitadora de flujo: mantiene el tablero de Trello, vigila el límite de trabajo en curso y gestiona los bloqueos.
Jessica Gil	Product Owner y contacto con el cliente: prioriza el backlog y valida los entregables con el observatorio.

Integrante	Rol en el flujo de trabajo (Kanban)
Lina Bautista	Responsable de calidad: revisa las tarjetas en la columna de revisión antes de darlas por terminadas.
Jorge Reza	Integrador: responsable del repositorio, de las ramas individuales y de la integración entre módulos.

y un cronograma que se ajusta de acuerdo a las fechas de los entregables:

Fase	Inicio	Fin	Entregable
1. Análisis y modelado conceptual	Agosto de 2026	2 de septiembre de 2026	Entregable 1
2. Diseño y desarrollo relacional	3 de septiembre de 2026	19 de octubre de 2026	Entregable 2
3. No relacional y visualización	Segunda semana de octubre	Segunda semana de noviembre	Entregable 3
4. Consolidación y pruebas	Tercera semana de noviembre	Última semana de noviembre	Entregable final

Igualmente se tiene la definición de tareas y el aporte de cada integrante del equipo para cada uno de los entregables:

Integrante	Entregable 1	Entregable 2	Entregable 3	Entregable final
Mariana	Requisitos e historias de Ocupado, RamaActividad y	Tablas ocupado, rama_actividad y usuario; roles.	Colección de fuentes.	Coordinación del plan de pruebas.

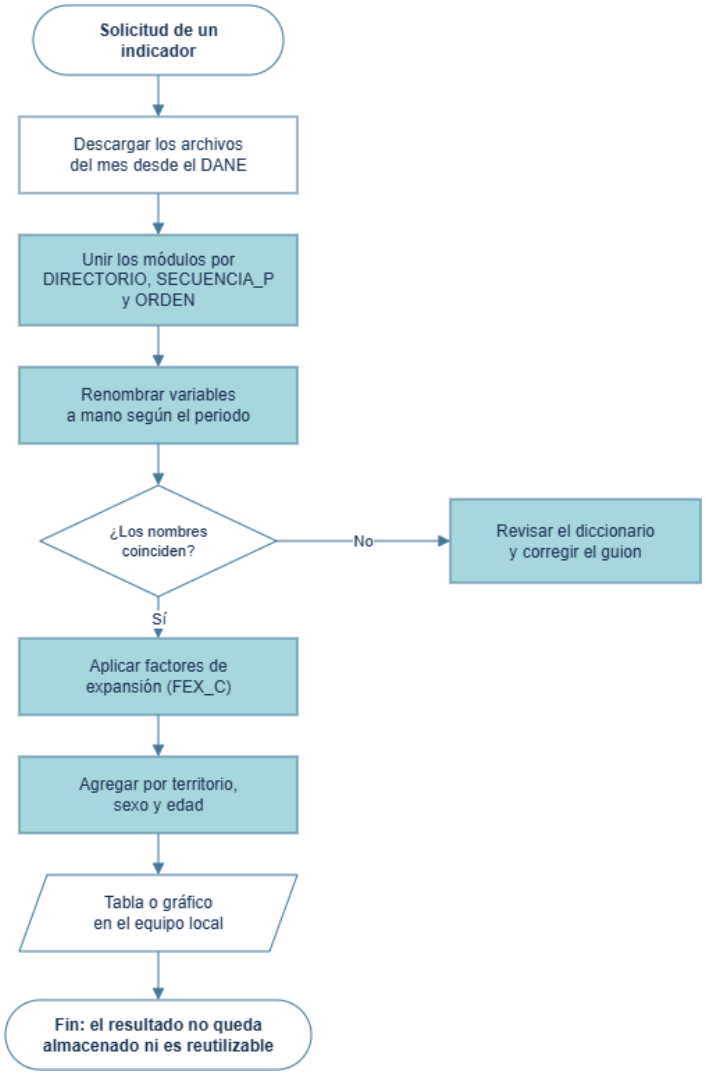
Integrante	Entregable 1	Entregable 2	Entregable 3	Entregable final
	Usuario (HU-05 a HU-07).			
Jessica	Coordinación del documento; contexto, problema y objetivos; historias de Indicador, RangoEdad y Territorio (HU-10 a HU-16).	Tablas indicador, rango_edad y territorio; procedimientos de cálculo y disparador de auditoría.	Colección de metodologías; coordinación del tablero.	Documentación técnica.
Lina	Requisitos e historias de Persona, Periodo y Sexo (HU-01 a HU-04); modelado de clases y MER.	Tablas persona, periodo y sexo; carga mensual de personas desde CSV.	Colección del diccionario de variables.	Réplica de indicadores oficiales.
Jorge	Requisitos e historias de Desocupado y TipoIndicador (HU-08 y HU-09); diagramas.	Tablas desocupado y tipo_indicador; consultas multitabla.	Tablero en Power BI y exportación.	Integración del repositorio.

6. Propuesta de solución

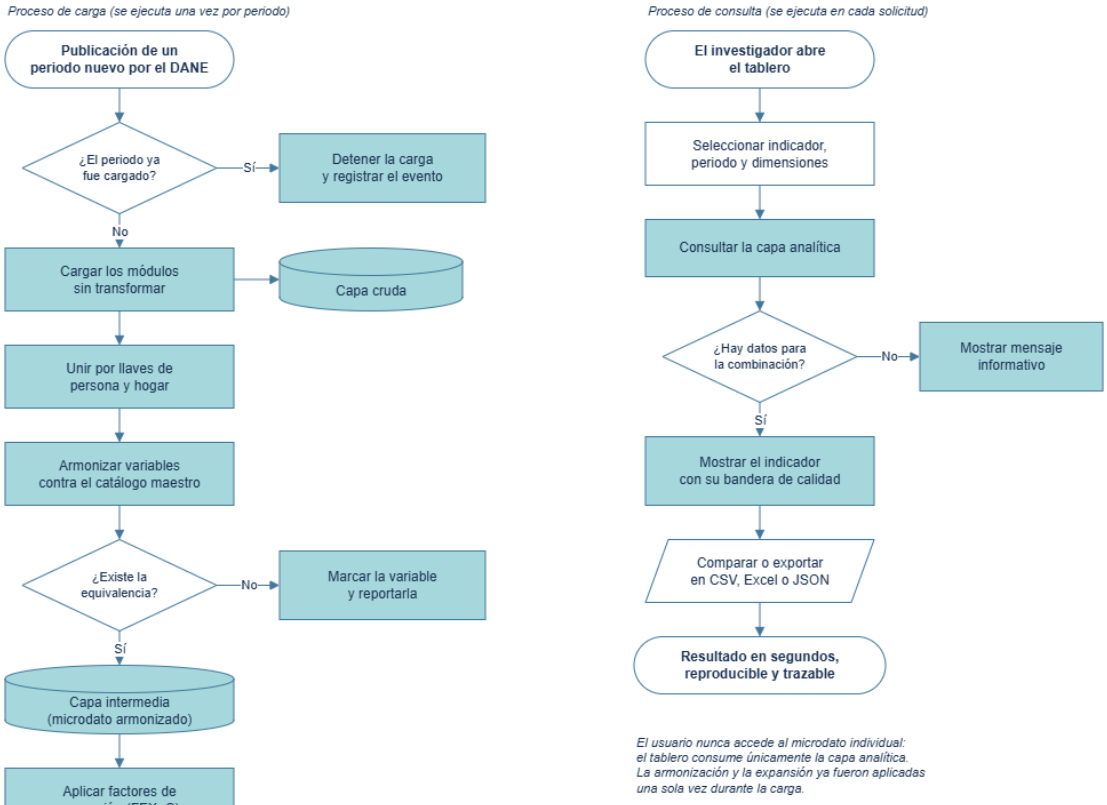
El enfoque predominante en equipos de investigadores u observatorios consiste en procesar los archivos crudos de la encuesta mediante rutinas locales en Stata o en R, con paquetes que soportan diseños muestrales complejos. Este es un enfoque válido para un análisis puntual, pero no soluciona el problema de reprocesamiento, ya que cada indicador de estima desde cero, la memoria de la máquina limita el número de periodos que pueden manipularse a la vez y no existe una capa que varias personas puedan consultar de forma concurrente.

En el contexto nacional, Otero-Cortés et al. (2025) muestran el valor de la GEIH como sus límites, la encuesta es representativa a nivel nacional para zonas urbanas y rurales y para las principales ciudades y áreas metropolitanas, pero las muestras recolectadas a nivel municipal fuera de esas ciudades no son representativas y no todos los municipios se muestrean simultáneamente. Esta constatación es la que sustenta la delimitación territorial adoptada.
De acuerdo con esto se muestran las alternativas de la solución con diagramas de flujo:

Alternativa 1. Rutina local en Stata o R



Alternativa 2. Arquitectura por capas con base de datos y tablero



Además se presenta una tabla comparativa de ambas alternativas.

Criterio	Alternativa 1	Alternativa 2 (seleccionada)
Reutilización del procesamiento	Nula: cada indicador se recalcula desde cero.	Total: la armonización y la expansión se aplican una vez.

Criterio	Alternativa 1	Alternativa 2 (seleccionada)
Reproducibilidad	Depende del guión y del criterio de quien lo ejecuta.	Garantizada por la trazabilidad de cargas y el versionado.
Tiempo de respuesta	Días, por la preparación manual de cada serie.	Segundos, sobre tablas agregadas.
Acceso concurrente	No: cada quien trabaja sobre su copia local.	Sí: varios usuarios consultan el mismo tablero.
Control de calidad	Manual y no sistemático.	Automático, con coeficiente de variación y banderas.
Costo	Bajo inicial, alto acumulado en horas.	Medio inicial, bajo acumulado.
Curva de aprendizaje	Baja.	Media.
Ajuste al curso	No cubre bases de datos ni visualización.	Cubre relacional, no relacional y tablero.

De acuerdo a lo anterior, se selecciona la alternativa 2, ya que lo más importante no es el rendimiento sino la reproducibilidad, ya que el problema que el cliente describe es que en algunos casos el indicador puede dar distinto según quién lo calcule y eso se resuelve fijando el procesamiento en un lugar único y auditable. Igualmente, el rendimiento y el acceso concurrente son consecuencias favorables de esa decisión. Y la alternativa 1 se descarta porque reproduce el problema que se quiere resolver.

Además con la alternativa seleccionada, los datos se procesan en dos etapas, la primera es un cuaderno de python para preparar los microdatos de DANE y MySQL los almacena, los verifica y calcula los indicadores. Por lo tanto, antes de llegar a MySQL los microdatos pasan por un cuaderno de python que se ejecuta en Google Colab o Visual Studio Code que permite quedarse solo con las tablas y variables que se necesitan para estimar los indicadores.

Base de la GEIH	**Variables que se conservan**	**Tabla destino**
Características generales, seguridad social en salud y educación	DIRECTORIO, SECUENCIA_P, ORDEN, MES, P3271 (sexo), P6040 (edad), CLASE, AREA y FEX_C18 (factor de expansión)	persona
Ocupados	DIRECTORIO, SECUENCIA_P, ORDEN, RAMA2D_R4 (rama de actividad a dos dígitos, que se agrupa en 13 ramas), P6800 (horas trabajadas), INGLABO (ingreso laboral) y P6920 (cotización a pensión)	ocupado
Desocupados (archivo de No ocupados)	DIRECTORIO, SECUENCIA_P, ORDEN y DSI (se conservan solo los registros con DSI = 1)	desocupado

Luego, los tres archivos CSV que genera el cuaderno de Python (persona, ocupado y desocupado) se cargan en MySQL con la instrucción LOAD DATA, en ese orden: primero persona y después ocupado y desocupado, que dependen de ella. Antes se registra el periodo nuevo en el catálogo periodo, y después se verifica la carga y se calculan los indicadores del mes. Las tablas de microdato conservan los datos tal como los publica el DANE: no se modifican ni se eliminan registros, solo se agregan los de cada periodo nuevo.

7. Requisitos del sistema

Requisitos Funcionales (RQF) de alto nivel.

Código	**Requisito de alto nivel**
RQF-AL-01	El sistema debe administrar los usuarios y registrar la trazabilidad de todas las cargas.
RQF-AL-02	El sistema debe almacenar la información de personas, ocupados y desocupados de la GEIH ya preparada para su consulta y cálculo.

Código	Requisito de alto nivel
RQF-AL-03	El sistema debe administrar las dimensiones de análisis: periodo, sexo, rango de edad, territorio y rama de actividad.
RQF-AL-04	El sistema debe definir los tipos de indicador y asociarlos a sus dimensiones.
RQF-AL-05	El sistema debe calcular y almacenar los indicadores ponderados con su coeficiente de variación y su bandera de confiabilidad.

Requisitos Funcionales (RQF) de bajo nivel.

Código	Requisito	Clase	Usuario
RQF-001	El sistema debe permitir cargar cada mes en la tabla persona, a partir de un archivo CSV ya preparado, los registros de Características generales con su factor de expansión, su clase y su área, agregando los periodos nuevos sin alterar los ya cargados.	Persona	Ingeniero de datos
RQF-002	El sistema debe identificar cada registro mediante los campos de identificación de la GEIH, evitando duplicados dentro de un mismo periodo.	Persona	Ingeniero de datos
RQF-003	El sistema debe clasificar a cada persona como parte de la población en edad de trabajar (PET) cuando tiene quince años o más.	Persona	Ingeniero de datos

RQF-004	El sistema debe permitir consultar los registros de personas mediante filtros de edad, sexo, periodo y territorio.	Persona	Ingeniero de datos
RQF-005	El sistema no debe permitir modificar ni eliminar los registros de persona, ocupado y desocupado una vez cargados; solo debe admitir la incorporación de periodos nuevos.	Persona	Administrador
RQF-006	El sistema debe cargar cada mes en la tabla ocupado, a partir de un archivo CSV ya preparado, a las personas ocupadas con su rama de actividad, horas trabajadas, ingreso laboral y cotización a pensión.	Ocupado	Ingeniero de datos
RQF-007	El sistema no debe permitir que una misma persona exista a la vez en Ocupado y en Desocupado.	Ocupado	Ingeniero de datos
RQF-008	El sistema debe validar que cada ocupado exista en persona y pertenezca a la PET antes de registrarlo.	Ocupado	Ingeniero de datos
RQF-009	El sistema debe permitir consultar los registros de ocupados.	Ocupado	Ingeniero de datos
RQF-010	El sistema debe cargar cada mes en la tabla desocupado, a partir de un archivo CSV ya preparado, el identificador de las personas desocupadas.	Desocupado	Ingeniero de datos
RQF-011	El sistema debe validar que cada desocupado exista en persona y pertenezca a la PET antes de registrarlo.	Desocupado	Ingeniero de datos

RQF-012	El sistema debe permitir consultar los registros de desocupados.	Desocupado	Ingeniero de datos
RQF-013	El sistema debe permitir registrar los periodos de la GEIH mediante el año y el mes correspondientes.	Periodo	Ingeniero de datos
RQF-014	El sistema debe validar que el mes esté entre 1 y 12 y evitar registros duplicados del mismo año y mes.	Periodo	Ingeniero de datos
RQF-015	El sistema debe permitir consultar y modificar los periodos registrados para seleccionar información de diferentes años y meses.	Periodo	Ingeniero de datos
RQF-016	El sistema debe permitir registrar las categorías de sexo utilizadas en la GEIH para clasificar la información.	Sexo	Ingeniero de datos
RQF-017	El sistema debe permitir consultar y modificar el catálogo de sexo, por si en el futuro el DANE incluye otras categorías.	Sexo	Ingeniero de datos
RQF-018	El sistema debe crear los rangos de edad 15-17, 18-28, 29-44, 45-59 y 60 o más.	RangoEdad	Ingeniero de datos
RQF-019	El sistema debe validar a qué rango pertenece una edad, dejando la edad final vacía en el rango de 60 o más.	RangoEdad	Ingeniero de datos
RQF-020	El sistema debe permitir consultar y modificar los rangos de edad.	RangoEdad	Ingeniero de datos
RQF-021	El sistema debe crear los territorios en los niveles nacional, zona (urbano y resto) y ciudad.	Territorio	Ingeniero de datos

RQF-022	El sistema debe estandarizar los códigos del área de la GEIH al territorio correspondiente.	Territorio	Ingeniero de datos
RQF-023	El sistema debe permitir consultar y modificar los territorios.	Territorio	Ingeniero de datos
RQF-024	El sistema debe mantener el catálogo de ramas de actividad con las 13 ramas agrupadas a partir de RAMA2D_R4 y dejar sin rama a los ocupados que no la informan.	RamaActividad	Ingeniero de datos
RQF-025	El sistema debe permitir consultar y modificar las ramas de actividad.	RamaActividad	Ingeniero de datos
RQF-026	El sistema debe crear cada tipo de indicador con su nombre, su fórmula y su periodicidad.	TipoIndicador	Investigador
RQF-027	El sistema debe asociar cada tipo de indicador a un periodo y, de forma opcional, a un sexo, un rango de edad, un territorio y una rama de actividad.	TipoIndicador	Investigador
RQF-028	El sistema debe permitir consultar y modificar las definiciones de los tipos de indicador.	TipoIndicador	Investigador
RQF-029	El sistema debe calcular la población económicamente activa, la tasa global de participación, la tasa de ocupación y la tasa de desocupación aplicando el factor de expansión.	Indicador	Investigador
RQF-030	El sistema debe calcular el salario promedio y las horas trabajadas de los ocupados aplicando el factor de expansión.	Indicador	Investigador

RQF-031	El sistema debe calcular la tasa de informalidad con base en la cotización a pensión de los ocupados.	Indicador	Investigador
RQF-032	El sistema debe calcular el coeficiente de variación de cada indicador estimado.	Indicador	Investigador
RQF-033	El sistema debe evaluar la confiabilidad de cada indicador según su coeficiente de variación y marcar los de baja confiabilidad.	Indicador	Investigador
RQF-034	El sistema debe almacenar cada indicador con su valor, su coeficiente de variación y su fecha de cálculo, asociado a un tipo de indicador.	Indicador	Ingeniero de datos
RQF-035	El sistema debe permitir consultar los indicadores filtrando por periodo, territorio, sexo, rango de edad y rama de actividad.	Indicador	Investigador
RQF-036	El sistema debe mostrar un mensaje informativo cuando no existan indicadores para la combinación de filtros seleccionada.	Indicador	Investigador
RQF-037	El sistema debe permitir exportar los indicadores consultados en formatos CSV y Excel.	Indicador	Investigador
RQF-038	El sistema debe entregar al tablero únicamente información agregada, sin exponer los microdatos individuales.	Indicador	Investigador
RQF-039	El sistema debe registrar usuarios con nombre, correo electrónico único y rol asignado.	Usuario	Administrador

RQF-040	El sistema debe asignar a cada usuario un rol que determine las operaciones que puede ejecutar.	Usuario	Administrador
RQF-041	El sistema debe permitir consultar y modificar los usuarios registrados.	Usuario	Administrador
RQF-042	El sistema debe asociar cada indicador calculado con el usuario que lo generó y con su fecha de cálculo, como mecanismo de trazabilidad.	Usuario	Investigador
RQF-043	El sistema debe permitir consultar, modificar e inactivar usuarios sin eliminar su registro, para conservar el historial de indicadores.	Usuario	Administrador
RQF-044	El sistema debe registrar en la tabla auditoria_indicador, mediante un disparador, cada inserción, modificación o eliminación de un indicador con su valor anterior, su valor nuevo, la fecha y el usuario.	Auditoría	Administrador
RQF-045	El sistema debe impedir que la tabla de auditoría se modifique o se borre de forma manual.	Auditoría	Administrador

8. Historias de Usuario.

HU-01 · Carga de personas

Módulo: M1 · Persona Requisitos asociados: RQF-001, RQF-002, RQF-005

Como ingeniero de datos, quiero cargar en la base de datos el archivo de personas del periodo ya preparado, para que cada persona encuestada quede registrada con un identificador único y su factor de expansión.

Criterios de aceptación:

- Cada mes se agrega un archivo CSV nuevo sin modificar los periodos ya cargados.
- Cada registro conserva su factor de expansión, su clase y su área
- No se registra dos veces a la misma persona en un periodo.
- Los registros cargados no se pueden modificar ni eliminar.
- Los registros con campos obligatorios vacíos se rechazan y se reportan.

Escenarios:

Escenario 1: Carga exitosa

Dado que el archivo de personas del periodo está preparado y verificado. Cuando el ingeniero de datos ejecuta la carga. Entonces las personas quedan registradas con su identificador y el sistema informa el total de registros cargados.

Escenario 2: Persona repetida

Dado que la persona ya existe en el periodo. Cuando el archivo trae de nuevo ese registro. Entonces el sistema lo rechaza y lo incluye en el reporte de duplicados.

HU-02 · Clasificación de la población en edad de trabajar

Módulo: M1 · Persona Requisitos asociados: RQF-003, RQF-004

Como ingeniero de datos, quiero que el sistema marque a cada persona como parte o no de la población en edad de trabajar, para poder calcular las tasas de participación, ocupación y desocupación sobre la población correcta.

Criterios de aceptación:

- Se marca como PET a toda persona de quince años o más.
- Las personas menores de quince años quedan registradas pero no marcadas como PET.
- La marca se puede consultar para cada persona.
- La marca se calcula sola a partir de la edad.

Escenarios:

Escenario 1: Persona en edad de trabajar

Dado que una persona registrada con 34 años. Cuando se ejecuta la clasificación. Entonces la persona queda marcada como PET.

Escenario 2: Persona menor de quince años

Dado que una persona registrada con 12 años. Cuando se ejecuta la clasificación. Entonces la persona no se marca como PET y no entra en los cálculos de las tasas.

HU-03 · Gestión de periodos

Módulo: M1 · Periodo Requisitos asociados: RQF-013 a RQF-015

Como ingeniero de datos, quiero registrar y consultar los periodos (año y mes) de la información cargada, para que cada persona y cada indicador queden asociados a un mes concreto de la serie.

Criterios de aceptación:

- Cada periodo tiene un año y un mes entre 1 y 12.
- No se puede crear un periodo que ya exista.
- Se pueden consultar los periodos disponibles.
- Los periodos permiten ampliar la serie hacia adelante y hacia atrás.

Escenarios:

Escenario 1: Periodo nuevo

Dado que el periodo agosto de 2026 no existe. Cuando el ingeniero de datos lo registra con un mes válido. Entonces el periodo queda disponible para asociar personas e indicadores.

Escenario 2: Mes inválido

Dado que se intenta registrar un periodo con el mes 13. Cuando el sistema valida el periodo. Entonces el registro se rechaza con un mensaje que indica que el mes debe estar entre 1 y 12.

HU-04 · Catálogo de sexo

Módulo: M1 · Sexo Requisitos asociados: RQF-016, RQF-017

Como ingeniero de datos, quiero mantener un catálogo de sexo con códigos estandarizados, para que todas las personas y los indicadores usen las mismas categorías al desagregar por sexo.

Criterios de aceptación:

- El catálogo contiene las categorías hombre y mujer con su identificador.
- Cada persona referencia una categoría existente del catálogo.

- Una categoría se puede consultar y modificar sin alterar los identificadores.

Escenarios:

Escenario 1: Consulta del catálogo

Dado que el catálogo de sexo está cargado. Cuando el usuario consulta las categorías. Entonces el sistema muestra cada categoría con su identificador.

Escenario 2: Categoría inexistente

Dado que un archivo de personas trae un código de sexo que no está en el catálogo. Cuando se ejecuta la carga. Entonces el registro se rechaza y se reporta para su corrección.

HU-05 · Registro de ocupados

Módulo: M2 · Ocupado Requisitos asociados: RQF-006 a RQF-009

Como ingeniero de datos, quiero cargar a las personas ocupadas con su rama de actividad, horas trabajadas, ingreso y cotización a pensión, para poder calcular el salario promedio, las horas trabajadas y la tasa de informalidad.

Criterios de aceptación:

- Cada ocupado corresponde a una persona ya registrada y marcada como PET.
- Un ocupado tiene rama de actividad, horas trabajadas, ingreso laboral y cotización a pensión.
- Una persona no puede ser ocupada y desocupada a la vez.
- Un ocupado sin rama informada se registra sin rama y no entra en los indicadores por rama.

Escenarios:

Escenario 1: Ocupado válido

Dado que la persona existe y es PET. Cuando se carga como ocupada con sus horas e ingresos. Entonces el registro queda guardado y asociado a esa persona.

Escenario 2: Persona ya desocupada

Dado que la persona ya está registrada como desocupada. Cuando se intenta cargarla como ocupada. Entonces el sistema rechaza el registro y lo reporta como inconsistente.

HU-06 · Catálogo de ramas de actividad

Módulo: M2 · RamaActividad Requisitos asociados: RQF-024, RQF-025

Como ingeniero de datos, quiero mantener el catálogo de las 13 ramas de actividad agrupadas a partir de RAMA2D_R4, para poder desagregar los indicadores por sector económico con categorías estandarizadas.

Criterios de aceptación:

- Cada rama tiene su identificador (1 a 13) y su nombre.
- Cada ocupado referencia una rama existente o queda sin rama.
- El catálogo se puede consultar y modificar.

Escenarios:

Escenario 1: Consulta de ramas

Dado que el catálogo está cargado. Cuando el usuario consulta las ramas. Entonces el sistema lista cada rama con su código y su nombre.

Escenario 2: Rama no informada

Dado que un ocupado trae la rama vacía, con un punto o como no sabe, no informa. Cuando se ejecuta la carga. Entonces el ocupado se registra sin rama y no se cuenta en los indicadores por rama.

HU-07 · Administración de usuarios y roles

Módulo: M2 · Usuario Requisitos asociados: RQF-039 a RQF-043

Como administrador del sistema, quiero registrar a los usuarios, asignarles un rol y desactivarlos cuando ya no participan, para controlar quién puede consultar indicadores y quién puede administrar la base, sin perder el historial de indicadores.

Criterios de aceptación:

- Cada usuario tiene nombre, correo y rol.
- El rol determina las operaciones permitidas.

- No se registran dos usuarios con el mismo correo.
- Cada indicador queda asociado al usuario que lo calculó y a su fecha de cálculo.
- Un usuario se puede inactivar sin eliminar su registro, para conservar el historial.

Escenarios:

Escenario 1: Usuario nuevo

Dado un investigador sin cuenta. Cuando el administrador lo registra con el rol de consulta. Entonces el usuario queda habilitado solo para consultar indicadores.

Escenario 2: Correo repetido

Dado que ya existe un usuario con ese correo. Cuando el administrador intenta registrar otro con el mismo correo. Entonces el sistema rechaza el registro e informa que el correo ya está en uso.

Escenario 3: Usuario inactivo

Dado que un usuario ya no participa en el proyecto y calculó indicadores. Cuando el administrador lo desactiva. Entonces el usuario queda inactivo, su registro se conserva y sus indicadores siguen asociados a él.

HU-08 · Registro de desocupados

Módulo: M3 · Desocupado Requisitos asociados: RQF-010 a RQF-012

Como ingeniero de datos, quiero cargar el identificador de las personas desocupadas, para poder calcular la tasa de desocupación y la población económicamente activa.

Criterios de aceptación:

- Cada desocupado corresponde a una persona ya registrada y marcada como PET.
- El registro contiene únicamente el identificador de la persona.
- Una persona no puede ser desocupada y ocupada a la vez.
- Los registros inválidos se rechazan y se reportan.

Escenarios:

Escenario 1: Desocupado válido

Dado que la persona existe y es PET. Cuando se carga como desocupada. Entonces el registro queda guardado y asociado a esa persona.

Escenario 2: Persona fuera de la PET

Dado que la persona tiene menos de quince años. Cuando se intenta cargarla como desocupada. Entonces el sistema rechaza el registro porque no pertenece a la PET.

HU-09 · Definición de tipos de indicador

Módulo: M3 · TipoIndicador Requisitos asociados: RQF-026 a RQF-028

Como investigador, quiero definir cada tipo de indicador con su fórmula, su periodicidad y las dimensiones por las que se desagrega, para que el cálculo de cada indicador se haga siempre con la misma definición.

Criterios de aceptación:

- Cada tipo de indicador tiene nombre, fórmula y periodicidad.
- Cada tipo se asocia a un periodo de forma obligatoria.
- Sexo, rango de edad, territorio y rama de actividad son opcionales.
- Un tipo de indicador se puede consultar y modificar.

Escenarios:

Escenario 1: Definición con dimensiones

Dado que el investigador define la tasa de desocupación. Cuando la asocia al periodo, al sexo mujer y al territorio Nacional. Entonces el tipo queda registrado y listo para calcular su indicador.

Escenario 2: Sin periodo

Dado que el investigador define un tipo de indicador. Cuando intenta guardarlo sin periodo. Entonces el sistema no lo permite porque el periodo es obligatorio.

HU-10 · Cálculo de indicadores ponderados

Módulo: M4 · Indicador Requisitos asociados: RQF-029 a RQF-031, RQF-034

Como investigador, quiero que el sistema calcule la población económicamente activa, las tasas, el salario promedio, las horas trabajadas y la informalidad aplicando el factor de expansión, para obtener cifras que representen a toda la población y no solo a la muestra.

Criterios de aceptación:

- Todos los cálculos usan el factor de expansión de cada persona.
- Se calculan PEA, TGP, tasa de ocupación, tasa de desocupación, salario promedio, horas trabajadas y tasa de informalidad.
- Cada resultado se guarda con su fecha de cálculo y su tipo de indicador.
- Las personas sin factor de expansión se reportan y no entran en el cálculo.

Escenarios:

Escenario 1: Cálculo exitoso

Dado que las personas del periodo están cargadas y el tipo de indicador está definido. Cuando el investigador solicita el cálculo de la tasa de ocupación. Entonces el sistema guarda el valor ponderado con su fecha de cálculo.

Escenario 2: Sin datos del periodo

Dado que el periodo solicitado no tiene personas cargadas. Cuando se solicita el cálculo. Entonces el sistema no genera el indicador e informa que faltan datos.

HU-11 · Control de calidad estadística

Módulo: M4 · Indicador Requisitos asociados: RQF-032, RQF-033

Como investigador, quiero que el sistema calcule el coeficiente de variación de cada indicador y marque los poco confiables, para saber qué cifras se pueden usar con seguridad.

Criterios de aceptación:

- Cada indicador guardado tiene su coeficiente de variación.
- Los indicadores sobre el umbral quedan con bandera de baja confiabilidad.
- El tablero muestra la bandera junto a la cifra.
- El umbral aplicado queda documentado en la metodología.

Escenarios:

Escenario 1: Indicador confiable

Dado que un indicador con coeficiente de variación bajo el umbral. Cuando se evalúa su confiabilidad. Entonces el indicador queda marcado como confiable.

Escenario 2: Indicador poco confiable

Dado que un indicador con coeficiente de variación sobre el umbral. Cuando se evalúa su confiabilidad. Entonces el indicador queda marcado como de baja confiabilidad y el tablero lo advierte.

HU-12 · Gestión de rangos de edad

Módulo: M4 · RangoEdad Requisitos asociados: RQF-018 a RQF-020

Como ingeniero de datos, quiero definir los rangos de edad y validar a cuál pertenece cada persona, para desagregar los indicadores por grupos de edad comparables.

Criterios de aceptación:

- Los rangos son 15-17, 18-28, 29-44, 45-59 y 60 o más.
- Una edad pertenece a un único rango.
- El rango de 60 o más no tiene edad final.
- Los rangos se pueden consultar y modificar.

Escenarios:

Escenario 1: Edad dentro de un rango

Dado que una persona de 30 años. Cuando se valida su rango de edad. Entonces el sistema la asigna al rango 29-44.

Escenario 2: Edad fuera de los rangos.

Dado que una persona de 10 años. Cuando se valida su rango de edad. Entonces el sistema indica que no pertenece a ningún rango por estar bajo los quince años.

HU-13 · Catálogo de territorios

Módulo: M4 · Territorio Requisitos asociados: RQF-021 a RQF-023

Como ingeniero de datos, quiero mantener el catálogo de territorios con los niveles nacional, zona y ciudad, para poder desagregar los indicadores geográficamente de forma estandarizada.

Criterios de aceptación:

- El catálogo incluye Nacional, Urbano, Rural (resto) y las 13 ciudades de la GEIH.
- Cada territorio tiene un tipo (nacional, zona o ciudad).
- La clase (1 urbano, 2 rural) y el área (código DIVIPOLA) se conservan como los entrega el DANE.

- El catálogo se puede consultar y modificar.

Escenarios:

Escenario 1: Consulta del catálogo

Dado que el catálogo está cargado. Cuando el usuario consulta los territorios. Entonces el sistema muestra los 16 territorios con su tipo.

Escenario 2: Área fuera de las 13 ciudades

Dado que un registro trae un área que no está en el catálogo de ciudades. Cuando se ejecuta la verificación de la carga. Entonces el registro se cuenta en el reporte, sin rechazarlo, porque solo se calculan indicadores para las 13 ciudades.

HU-14 · Consulta y filtrado de indicadores

Módulo: M4 · Indicador Requisitos asociados: RQF-035, RQF-036, RQF-038

Como investigador, quiero filtrar y comparar los indicadores por periodo, territorio, sexo, rango de edad y rama de actividad, para encontrar rápido la cifra que necesito sin reprocesar los datos.

Criterios de aceptación:

- El tablero ofrece filtros de cinco dimensiones.
- Los filtros se aplican de forma simultánea.
- Se pueden comparar dos o más indicadores.
- Solo se muestra información agregada.

Escenarios:

Escenario 1: Filtro con resultados

Dado que existen indicadores calculados para el periodo. Cuando el investigador filtra por mujeres de 29 a 44 años a nivel nacional. Entonces el tablero muestra los indicadores que cumplen la combinación.

Escenario 2: Filtro sin resultados

Dado que no existen indicadores para la combinación elegida. Cuando el investigador aplica los filtros. Entonces el tablero muestra un mensaje informativo y permite restablecer los filtros.

HU-15 · Exportación de resultados

Módulo: M4 · Indicador Requisitos asociados: RQF-037

Como investigador, quiero descargar los indicadores consultados en CSV o Excel, para usarlos en informes y análisis propios.

Criterios de aceptación:

- El usuario elige el formato de descarga.
- El archivo conserva los datos consultados con sus encabezados.
- La exportación entrega solo información agregada.
- El sistema confirma cuando la descarga termina.

Escenarios:

Escenario 1: Exportación en CSV

Dado que el investigador tiene una consulta en pantalla. Cuando elige el formato CSV y descarga. Entonces recibe un archivo con los datos y encabezados de la consulta.

Escenario 2: Consulta vacía

Dado que la consulta no tiene resultados. Cuando el investigador intenta exportar. Entonces el sistema avisa que no hay datos para exportar.

HU-16 · Auditoría de cambios en indicadores

Módulo: M4 · Indicador Requisitos asociados: RQF-044, RQF-045

Como administrador del sistema, quiero que cada cambio sobre un indicador quede registrado automáticamente en una tabla de auditoría, para saber quién modificó una cifra, cuándo y qué valor tenía antes.

Criterios de aceptación:

- Un disparador registra cada inserción, modificación y eliminación de indicadores.
- El registro guarda valor anterior, valor nuevo, fecha y usuario.
- La tabla de auditoría no se puede modificar ni borrar manualmente.
- La auditoría no depende de que el usuario la solicite.

Escenarios:

Escenario 1: Modificación auditada

Dado que existe un indicador calculado. Cuando se actualiza su valor. Entonces la tabla de auditoría guarda el valor anterior, el nuevo, la fecha y el usuario.

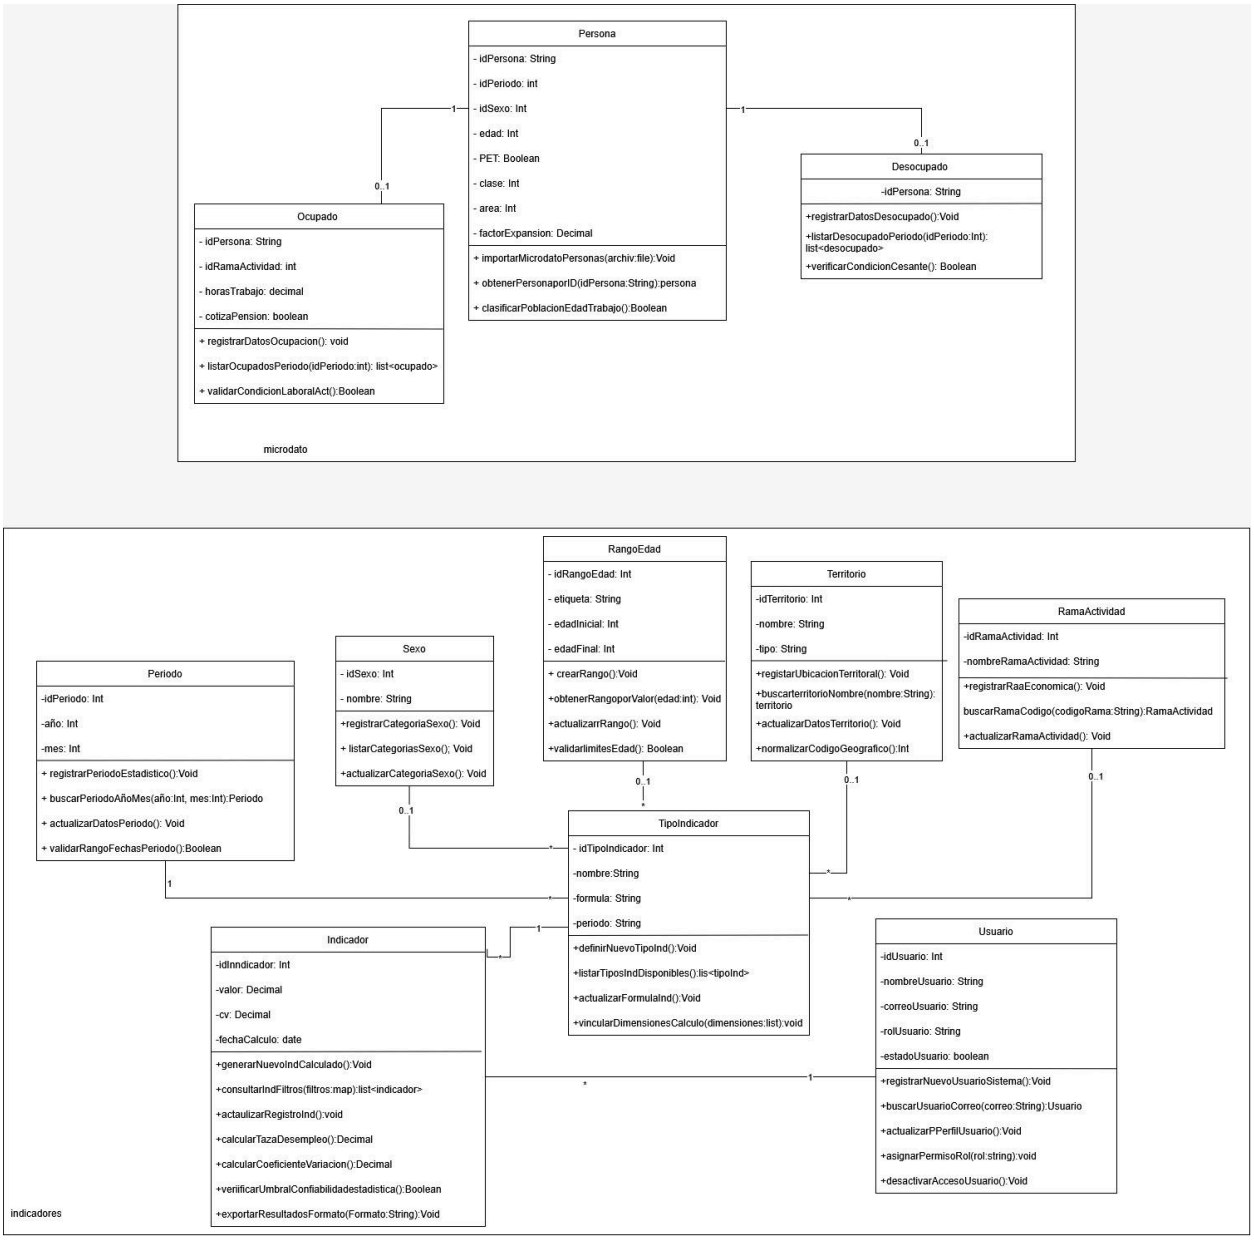
Escenario 2: Intento de borrar la auditoría

Dado que existen registros en la tabla de auditoría. Cuando un usuario intenta eliminarlos. Entonces el sistema no lo permite y los registros se conservan.

9. Modelado de la solución

Diagrama de Clases general del sistema.

El sistema se concibe bajo el paradigma orientado a objetos. Cada clase encapsula una responsabilidad del proceso y expone su comportamiento a través de métodos, de modo que un cambio en la fuente de datos se absorbe en una sola clase.



Interpretación:

La clase Persona está compuesta por los atributos idPersona, idPeriodo, idSexo, edad, pet, clase, area y factorExpansion, donde el atributo clave es idPersona, construido en el cuaderno de Python con el directorio, la secuencia_p y el orden. Cuenta con los métodos cargar() y consultar(), y con clasificarPET(), que marca si la persona pertenece a la población en edad de trabajar según su edad.

La clase Ocupado está compuesta por los atributos idPersona, idRama, horasTrabajo, ingreso y cotizaPension, donde el atributo clave es idPersona, el mismo de la persona a la que corresponde.

Cuenta con los métodos cargar() y consultar(), y con validarCondicion(), que verifica que la persona exista, esté en la PET y no sea desocupada.

La clase Desocupado está compuesta por los atributos idPersona, donde el atributo clave es idPersona. Cuenta con los métodos cargar() y consultar(), y con validarCondicion(), que verifica que la persona exista, esté en la PET y no sea ocupada.

La clase Usuario está compuesta por los atributos idUsuario, nombre, correo y rol, donde el atributo clave es idUsuario. Cuenta con los métodos crear(), consultar() y modificar(), y con asignarRol(), que define las operaciones permitidas a cada usuario.

La clase Periodo está compuesta por los atributos idPeriodo, anio y mes, donde el atributo clave es idPeriodo. Cuenta con los métodos crear(), consultar() y modificar(), y con validarPeriodo(), que revisa que el mes sea válido y que el periodo no exista.

La clase Sexo está compuesta por los atributos idSexo y nombre, donde el atributo clave es idSexo. Cuenta con los métodos crear(), consultar() y modificar().

La clase RangoEdad está compuesta por los atributos idRangoEdad, etiqueta, edadInicial y edadFinal, donde el atributo clave es idRangoEdad y edadFinal es nulo en el rango de 60 años o más por tratarse de un intervalo abierto. Cuenta con los métodos crear(), consultar() y modificar(), y con validarEdad(), que determina a qué rango pertenece una edad.

La clase Territorio está compuesta por los atributos idTerritorio, nombre y tipo (nacional, zona o ciudad), donde el atributo clave es idTerritorio. Cuenta con los métodos crear(), consultar() y modificar().

La clase RamaActividad está compuesta por los atributos idRama, que identifica una de las 13 ramas agrupadas a partir de RAMA2D_R4, y nombre, donde el atributo clave es idRama. Cuenta con los métodos crear(), consultar() y modificar().

La clase TipoIndicador está compuesta por los atributos idTipoIndicador, nombre, formula y periodicidad, además de la referencia al periodo (obligatoria) y a sexo, rango de edad, territorio y rama de actividad (opcionales), donde el atributo clave es idTipoIndicador y almacena la definición del indicador, no su valor. Cuenta con los métodos crear(), consultar() y modificar(), y con asociarDimensiones(), que vincula el tipo de indicador con las dimensiones por las que se desagrega.

La clase Indicador está compuesta por los atributos idIndicador, valor, cv y fechaCalculo, además de la referencia al tipo de indicador y al usuario, donde el atributo clave es idIndicador y

almacena el resultado final del cálculo. Cuenta con los métodos crear(), consultar() y modificar(), y con calcularValor(), calcularCV(), evaluarConfiabilidad() y exportar(), que calculan el valor ponderado, su coeficiente de variación, su bandera de confiabilidad y su salida hacia el tablero.
Las clases se relacionan mediante asociación de la siguiente forma. Una persona puede clasificarse como ocupada o como desocupada, o como ninguna de las dos, y cada ocupado o desocupado corresponde a una única persona. Un periodo se asocia a muchos tipos de indicador y cada tipo de indicador tiene exactamente un periodo, mientras que sexo, rango de edad, territorio y rama de actividad pueden asociarse a muchos tipos de indicador y cada tipo de indicador puede tener una o ninguna de ellas. Un tipo de indicador define muchos indicadores y cada indicador pertenece a un único tipo. Un usuario consulta muchos indicadores y cada indicador está asociado a un usuario. Las dos partes del modelo, el microdato y los indicadores, no se conectan por llaves: la segunda se construye a partir de la primera mediante procedimientos almacenados. La auditoría de los indicadores no es una clase, sino una tabla que alimenta un disparador.

10. Selección módulos por integrante.

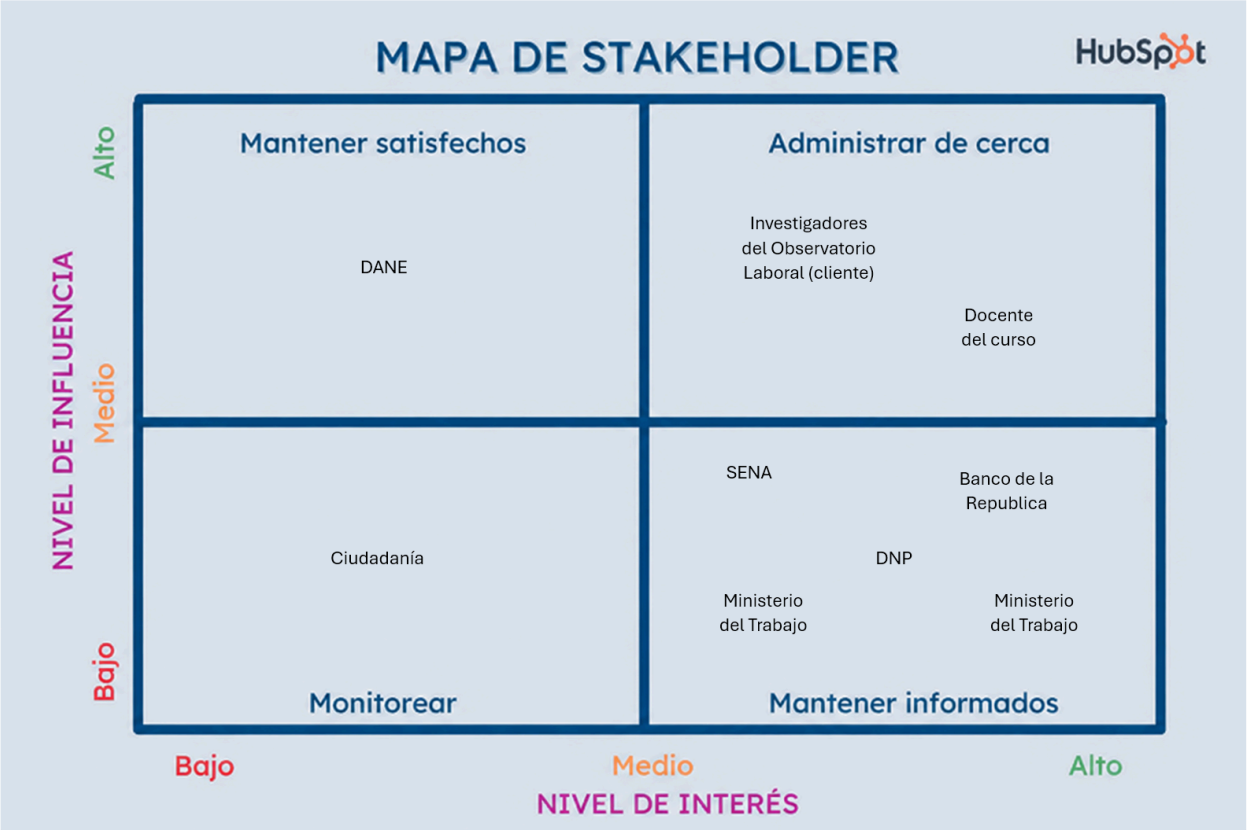
La solución se divide en 4 módulos, uno por integrante. La participación se realizó por agrupación de clases que tienen el mismo objetivo, de modo que cada módulo es coherente con las clases del diagrama de clases.

Módulo	**Responsable**	**Clases del modelo de datos**	**Alcance**
M1 · Persona, Periodo y Sexo	Lina	Persona, Periodo, Sexo	Carga de personas, clasificación de la PET, catálogo de periodos y catálogo de sexo.
M2 · Ocupado, RamaActividad y Usuario	Mariana	Ocupado, RamaActividad, Usuario	Carga de ocupados, catálogo de ramas de actividad, usuarios y roles.

Módulo	Responsable	Clases del modelo de datos	Alcance
M3 · Desocupado y TipoIndicador	Jorge	Desocupado, TipoIndicador	Carga de desocupados y definición de los tipos de indicador con sus dimensiones.
M4 · Indicador, RangoEdad y Territorio	Jessica	Indicador, RangoEdad, Territorio	Cálculo y calidad de los indicadores, rangos de edad, territorios, consulta, exportación y auditoría.

11. Mapa de Stakeholders.

Los actores del proyecto se clasifican según su nivel de influencia y su nivel de interés siguiendo la matriz de Mendelow. En el cuadrante de alta influencia y alto interés se ubican los investigadores del Observatorio Laboral, que son el cliente y definen los requisitos, y el docente del curso, que evalúa los entregables; ambos exigen administración cercana y validación continua. El DANE se sitúa en alta influencia y bajo interés: no participa del desarrollo, pero cualquier cambio en su metodología o en su calendario de publicación condiciona el sistema, por lo que la estrategia consiste en seguir fielmente sus definiciones. En el cuadrante de bajo poder y alto interés están el Ministerio del Trabajo, el Departamento Nacional de Planeación, el Banco de la República y el SENA, entidades que consumirían los indicadores sin intervenir en su construcción y a las que corresponde mantener informadas. Finalmente, la ciudadanía se ubica en bajo poder y bajo interés directo, aunque es la beneficiaria última de las decisiones de política que se apoyan en estas cifras.

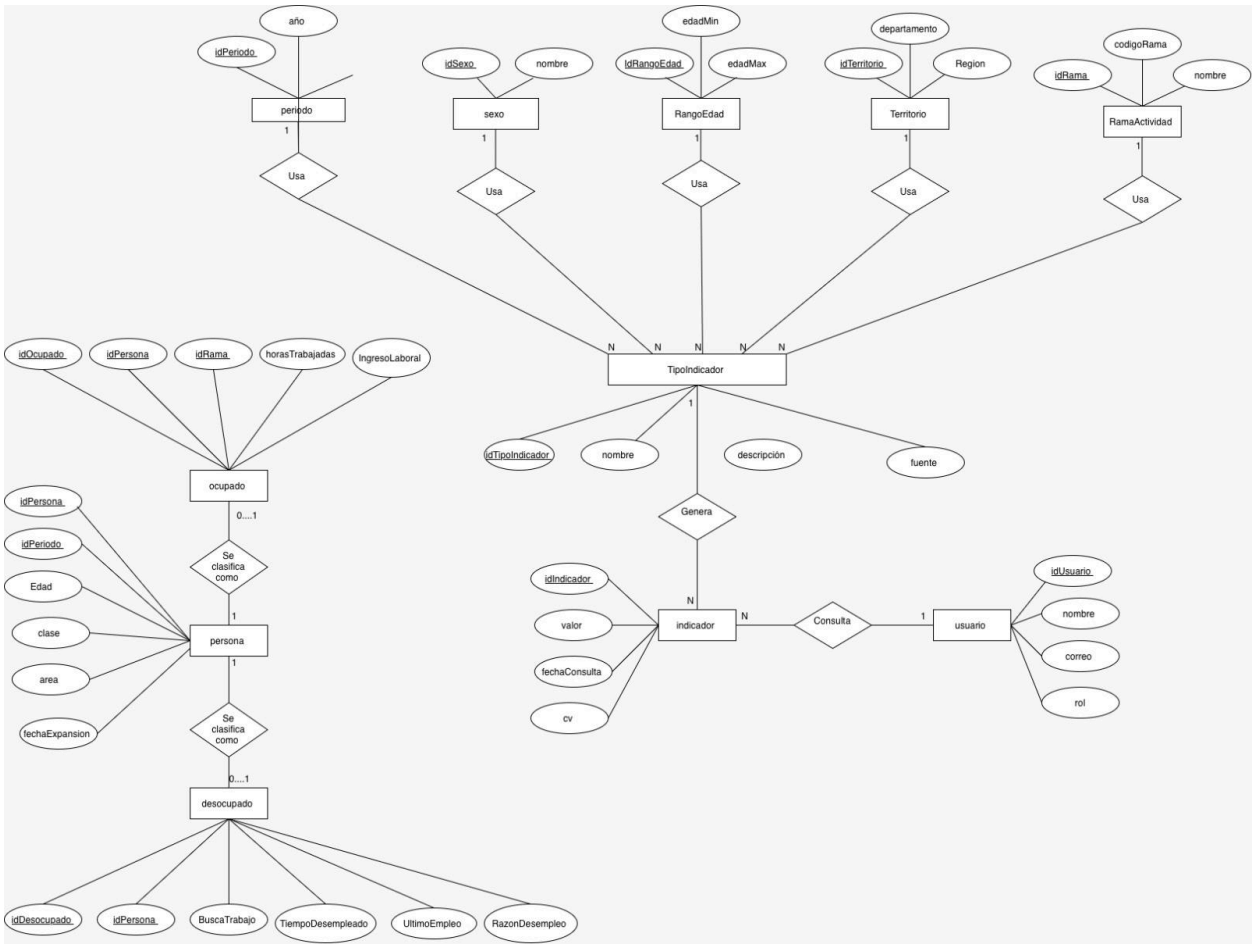


12. Diagrama de Clases específico de modelo de datos relacional (MER).

A diferencia del diagrama general, este modelo recoge únicamente las entidades que persisten, con sus atributos y sus multiplicidades, sin lógica de proceso. Se organiza en dos partes: el microdato, con Persona, Ocupado y Desocupado, y los indicadores, con las cinco dimensiones, TipoIndicador, Indicador y Usuario.

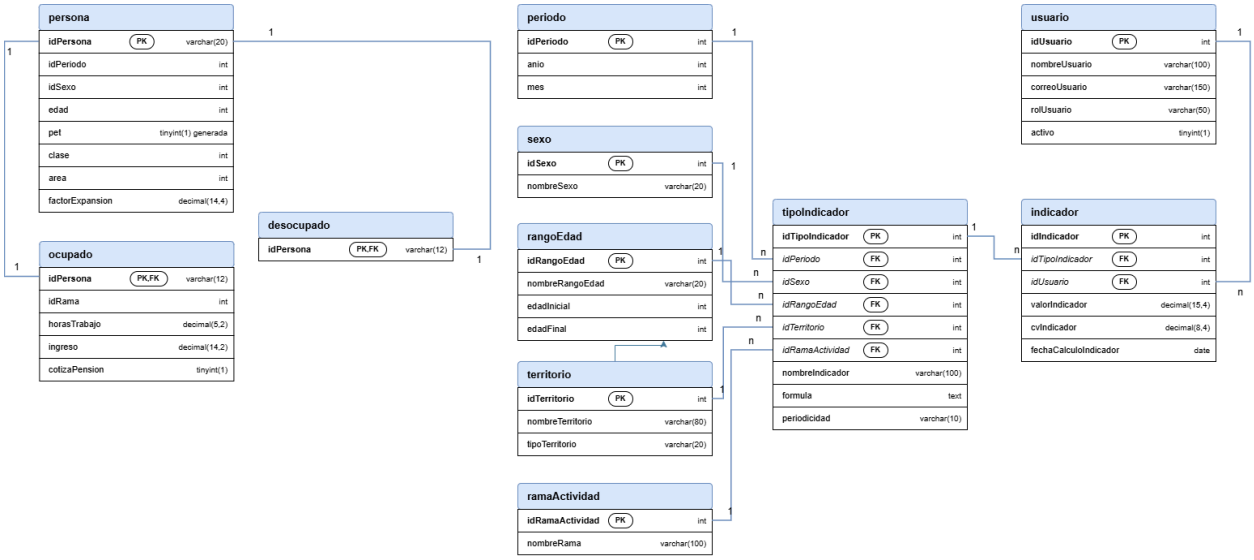
Persona se relaciona con Ocupado y con Desocupado mediante la relación se clasifica como, que es de uno a cero o uno en ambos casos: una persona puede ser ocupada, desocupada o ninguna de las dos, y un ocupado o un desocupado corresponde a una sola persona. Periodo se relaciona de uno a muchos con TipoIndicador porque todo tipo de indicador tiene periodo, mientras que Sexo, RangoEdad, Territorio y RamaActividad se relacionan de cero o uno a muchos, porque un tipo de indicador puede o no desagregarse por cada una. TipoIndicador define muchos Indicador y Usuario consulta muchos Indicador. No hay relaciones entre las dos partes, ya que los

indicadores se calculan desde el microdato con procedimientos almacenados, por lo que el modelo no requiere una relación de muchos a muchos ni una entidad débil intermedia.



13. Modelo conceptual entidad-relación (ER).

El modelo conceptual traduce las clases anteriores a entidades y relaciones con sus cardinalidades. La relación entre Microdato e Indicador es de muchos a muchos, ya que un mismo registro alimenta varios indicadores y un indicador se calcula a partir de muchos registros. Siguiendo las reglas de normalización, esa relación se resuelve mediante la entidad débil CalculoIndicador, cuya existencia depende de las entidades que la identifican y que almacena el valor calculado junto con su medida de precisión.



Entidad	**Tipo**	**Relación principal**
Persona	Fuerte	Se clasifica como ocupado o desocupado, con cardinalidad 0..1 en cada caso.
Ocupado, Desocupado	Dependientes de Persona	Comparten la llave de persona; cada una corresponde a una única persona.
Periodo	Fuerte	Se relaciona de uno a muchos con TipoIndicador y es obligatoria.
Sexo, RangoEdad, Territorio, RamaActividad	Fuertes	Se relacionan de cero o uno a muchos con TipoIndicador.
TipoIndicador	Fuerte	Recibe las llaves de las cinco dimensiones y define muchos indicadores.
Indicador	Fuerte	Pertenece a un tipo de indicador y es consultado por un usuario.
Usuario	Fuerte	Consulta muchos indicadores.

Entidad	Tipo	Relación principal
Persona	Fuerte	Se clasifica como ocupado o desocupado, con cardinalidad 0..1 en cada caso.
auditoria_indicador	Tabla de apoyo	Se llena con un disparador al cambiar un indicador; no tiene llave foránea.

14. Diccionarios de datos de las tablas

Tabla: persona

Fecha: 18/10/2026

Descripción: Tabla que almacena a cada persona de la GEIH en un periodo, con su información demográfica, su factor de expansión y si pertenece a la población en edad de trabajar. No admite modificaciones ni eliminaciones.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idPersona	VARCHAR	12	Primary Key	Identificador único. Concatenación de directorio (7), secuencia_p (2) y orden (2), con ceros a la izquierda, armada en el script de Python.
idPeriodo	INT	—	Not Null	Periodo al que pertenece el registro. Se valida contra el catálogo periodo, sin llave foránea.
idSexo	INT	—	Not Null	Sexo de la persona. Se valida contra el catálogo sexo, sin llave foránea.

edad	INT	—	Not Null	Edad en años cumplidos.
pet	TINYINT	1	Columna generada	Indica si pertenece a la población en edad de trabajar (1 = sí, 0 = no). Se calcula sola como edad >= 15.
clase	TINYINT	—	Not Null	Clase de la GEIH: 1 urbano (cabecera), 2 rural (resto).
area	INT	—	Nulo permitido	Código de área (DIVIPOLA) tal como lo entrega el DANE; puede venir vacío.
factorExpansion	DECIMAL	14,4	Not Null	Factor de expansión de la persona publicado por el DANE.

Tabla: ocupado

Fecha: 18/10/2026

Descripción: Tabla que contiene a las personas ocupadas y las variables propias de su ocupación. No admite modificaciones ni eliminaciones.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idPersona	VARCHAR	12	Primary Key, Foreign Key	Persona ocupada (referencia a persona).
idRama	INT	—	Nulo permitido	Rama de actividad (1 a 13). Queda nula si no sabe, no informa o viene vacía. Se valida contra el catálogo

				ramaActividad, sin llave foránea.
horasTrabajo	DECIMAL	5,2	—	Horas trabajadas a la semana.
ingreso	DECIMAL	14,2	—	Ingreso laboral mensual en pesos corrientes.
cotizaPension	TINYINT	1	Not Null	Indica si cotiza a pensión (1 = sí, 0 = no).

Tabla: desocupado

Fecha: 18/10/2026

Descripción: Tabla que contiene a las personas desocupadas, identificadas solo por su idPersona. No admite modificaciones ni eliminaciones.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idPersona	VARCHAR	12	Primary Key, Foreign Key	Persona desocupada (referencia a persona).

Tabla: usuario

Fecha: 18/10/2026

Descripción: Tabla que contiene a los usuarios autorizados del sistema.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idUsuario	INT	—	Primary Key, Auto_increment	Identificador del usuario.
nombreUsuario	VARCHAR	100	Not Null	Nombre completo del usuario.

correoElectronico	VARCHAR	150	Not Null, Unique	Correo del usuario.
rolUsuario	VARCHAR	50	Not Null	Rol que define sus permisos (administrador, ingeniero de datos o investigador).
activo	TINYINT	1	Not Null, Default 1	Estado del usuario: 1 = activo, 0 = inactivo. Un usuario inactivo no se elimina, para conservar el historial de sus indicadores.

Tabla: periodo

Fecha: 18/10/2026

Descripción: Tabla de dimensión para la segmentación temporal.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idPeriodo	INT	—	Primary Key	Identificador del periodo.
anio	INT	—	Not Null	Año del periodo.
mes	TINYINT	—	Not Null, Check 1 a 12	Mes del periodo.

Tabla: sexo

Fecha: 18/10/2026

Descripción: Tabla de dimensión para la clasificación por sexo.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idSexo	INT	—	Primary Key	Identificador de la categoría.

nombreSexo	VARCHAR	20	Not Null, Unique	Nombre de la categoría (hombre, mujer).

Tabla: rangoEdad

Fecha: 18/10/2026

Descripción: Tabla de dimensión para la agrupación etaria.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idRangoEdad	INT	—	Primary Key	Identificador del rango.
etiquetaRango	VARCHAR	20	Not Null, Unique	Etiqueta del rango (por ejemplo, 18-28).
edadInicial	INT	—	Not Null	Edad mínima del rango.
edadFinal	INT	—	Nulo permitido	Edad máxima del rango; es nula en el rango de 60 o más.

Tabla: territorio

Fecha: 18/10/2026

Descripción: Tabla de dimensión para la ubicación geográfica.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idTerritorio	INT	—	Primary Key	Identificador del territorio.
nombreTerritorio	VARCHAR	80	Not Null	Nombre del territorio.
tipoTerritorio	VARCHAR	20	Not Null	Nivel: nacional, zona o ciudad.

Tabla: ramaActividad

Fecha: 18/10/2026

Descripción: Tabla de dimensión para los sectores de actividad económica.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idRama	INT	—	Primary Key	Identificador de la rama (1 a 13), agrupada a partir de RAMA2D_R4.
nombreRama	VARCHAR	200	Not Null	Nombre de la rama de actividad.

Tabla: tipoIndicador

Fecha: 18/10/2026

Descripción: Tabla que contiene la definición de cada indicador y las dimensiones por las que se desagrega.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idTipoIndicador	INT	—	Primary Key	Identificador del tipo de indicador.
idPeriodo	INT	—	Foreign Key, Not Null	Periodo del indicador (obligatorio).
idSexo	INT	—	Foreign Key, Nulo permitido	Sexo por el que se desagrega (opcional).
idRangoEdad	INT	—	Foreign Key, Nulo permitido	Rango de edad por el que se desagrega (opcional).
idTerritorio	INT	—	Foreign Key, Nulo permitido	Territorio por el que se desagrega (opcional). El nacional tiene el código 3.
idRama	INT	—	Foreign Key, Nulo permitido	Rama de actividad por la que se desagrega (opcional).

nombreIndicador	VARCHAR	100	Not Null	Nombre del indicador (por ejemplo, tasa de desocupación).
formula	TEXT	—	Not Null	Fórmula de cálculo.
periodicidad	VARCHAR	10	Not Null	Mensual o anual.

Tabla: indicador

Fecha: 18/10/2026

Descripción: Tabla que almacena el resultado calculado de cada indicador.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idIndicador	BIGINT	—	Primary Key, Auto_increment	Identificador del indicador calculado.
idTipoIndicador	INT	—	Foreign Key, Not Null	Definición a la que corresponde (referencia a tipoIndicador).
idUsuario	INT	—	Foreign Key, Not Null	Usuario que consulta o registra el indicador (referencia a usuario).
valor	DECIMAL	15,4	Not Null	Valor calculado con factor de expansión.
cv	DECIMAL	8,4	—	Coeficiente de variación del valor.
fechaCalculo	DATETIME	—	Not Null	Fecha y hora en que se calculó el indicador.

Tabla: auditoriaIndicador

Fecha: 18/10/2026

Descripción: Tabla que registra, mediante un disparador, cada cambio sobre la tabla indicador. No tiene llave foránea para conservar el historial aunque el indicador se elimine.

Campo	Tipo de dato	Tamaño	Restricción	Descripción
idAuditoria	BIGINT	—	Primary Key, Auto_increment	Identificador del registro de auditoría.
idIndicador	BIGINT	—	Not Null	Indicador afectado.
accion	VARCHAR	10	Not Null	Operación: INSERT, UPDATE o DELETE.
valorAnterior	DECIMAL	15,4	Nulo permitido	Valor antes del cambio.
valorNuevo	DECIMAL	15,4	Nulo permitido	Valor después del cambio.
usuarioBd	VARCHAR	100	Not Null	Usuario de la base de datos que hizo el cambio.
fechaAuditoria	DATETIME	—	Not Null	Fecha y hora del cambio.

15. Riesgos y mitigación

Riesgo	**Impacto**	**Mitigación**
El DANE publica una revisión retroactiva de un periodo ya cargado.	Medio	Respaldo previo y carga de la versión corregida del periodo a cargo del administrador de la base de datos, que es el único que puede intervenir las tablas de microdato.
Una combinación de filtros produce una estimación imprecisa.	Medio	Cálculo del coeficiente de variación y bandera de baja confiabilidad (RQF-032, RQF-033).

Riesgo	Impacto	Mitigación
Los indicadores calculados no coinciden con las cifras oficiales.	Alto	Fase 4 de validación mediante réplica de indicadores publicados por el DANE.
Concentración del conocimiento en un solo integrante por módulo.	Medio	Revisión cruzada obligatoria en la columna de revisión del tablero y ramas individuales en el repositorio.
La carga de los microdatos de varios años es lenta en MySQL.	Medio	Carga por lotes de los archivos limpios, un mes a la vez.

16. Planificación de tareas - Entregable 2

En esta fase están activas las historias de usuario HU-01 a HU-16 del modelo de datos. La tabla indica qué objeto de la base de datos cubre cada una y quién la desarrolla.

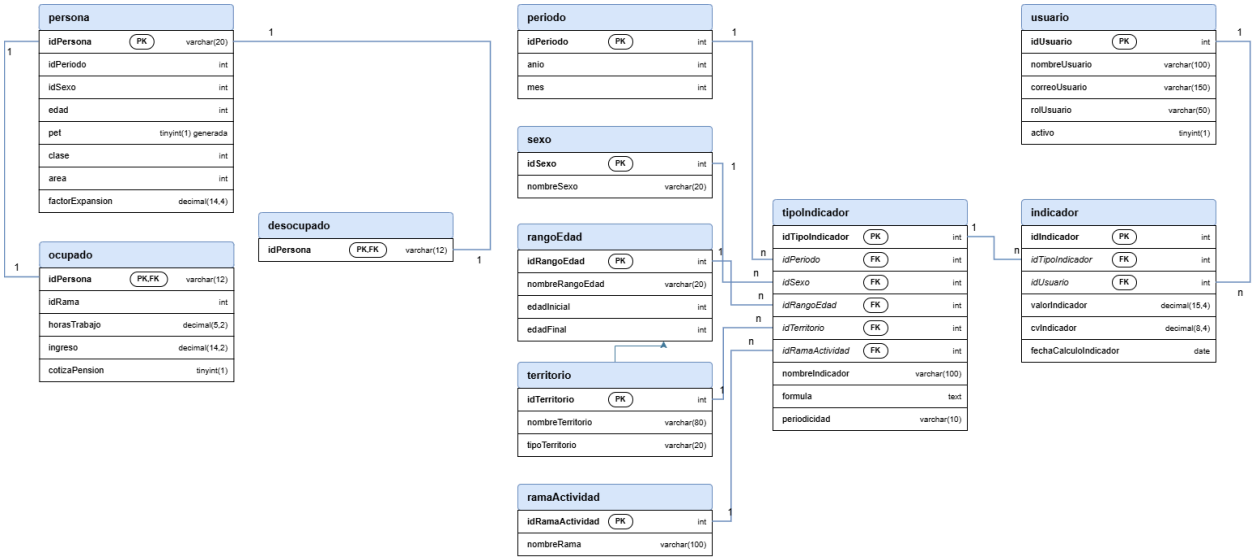
Historia	Objeto de la base de datos	Responsable
HU-01 Carga de personas	Tabla persona, llave primaria idPersona, carga mensual con LOAD DATA (script 10) y disparadores que impiden modificarla	Lina
HU-02 Población en edad de trabajar	Columna generada pet y función fnPet	Lina
HU-03 Gestión de periodos	Tabla periodo con restricción de mes y año-mes únicos	Lina
HU-04 Catálogo de sexo	Tabla sexo	Lina
HU-05 Registro de ocupados	Tabla ocupado y disparador trgOcupadoBi	Mariana

HU-06 Ramas de actividad	Tabla ramaActividad	Mariana
HU-07 Usuarios y roles	Tabla usuario con restricción de rol y correo único	Mariana
HU-08 Registro de desocupados	Tabla desocupado (solo idPersona) y disparador trgDesocupadoBi	Jorge
HU-09 Tipos de indicador	Tabla tipoIndicador con sus cinco llaves foráneas	Jorge
HU-10 Cálculo ponderado	Funciones fnPea, fnOcupados, fnDesocupados, fnInformales, fnSalarioPromedio, fnHorasPromedio, fnValorIndicador y procedimientos spCalcularIndicador, spCalcularPeriodo y spCopiarDefiniciones	Jessica
HU-11 Control de calidad	Funciones fnNMuestra, fnCvIndicador y fnConfiabilidad	Jessica
HU-12 Rangos de edad	Tabla rangoEdad	Jessica
HU-13 Territorios	Tabla territorio	Jessica
HU-14 Consulta y filtrado	Vistas vBase, vIndicadorDetalle, vIndicadorVigente, vResumenLaboralPeriodo y vOcupadosPorRama	Jorge
HU-15 Exportación	Las vistas se exportan a CSV o Excel desde el cliente de MySQL o desde Python	Lina
HU-16 Auditoría	Tabla auditoriaIndicador y disparadores trgIndicadorAi, trgIndicadorAu, trgIndicadorAd, trgAuditoriaBu y trgAuditoriaBd	Mariana

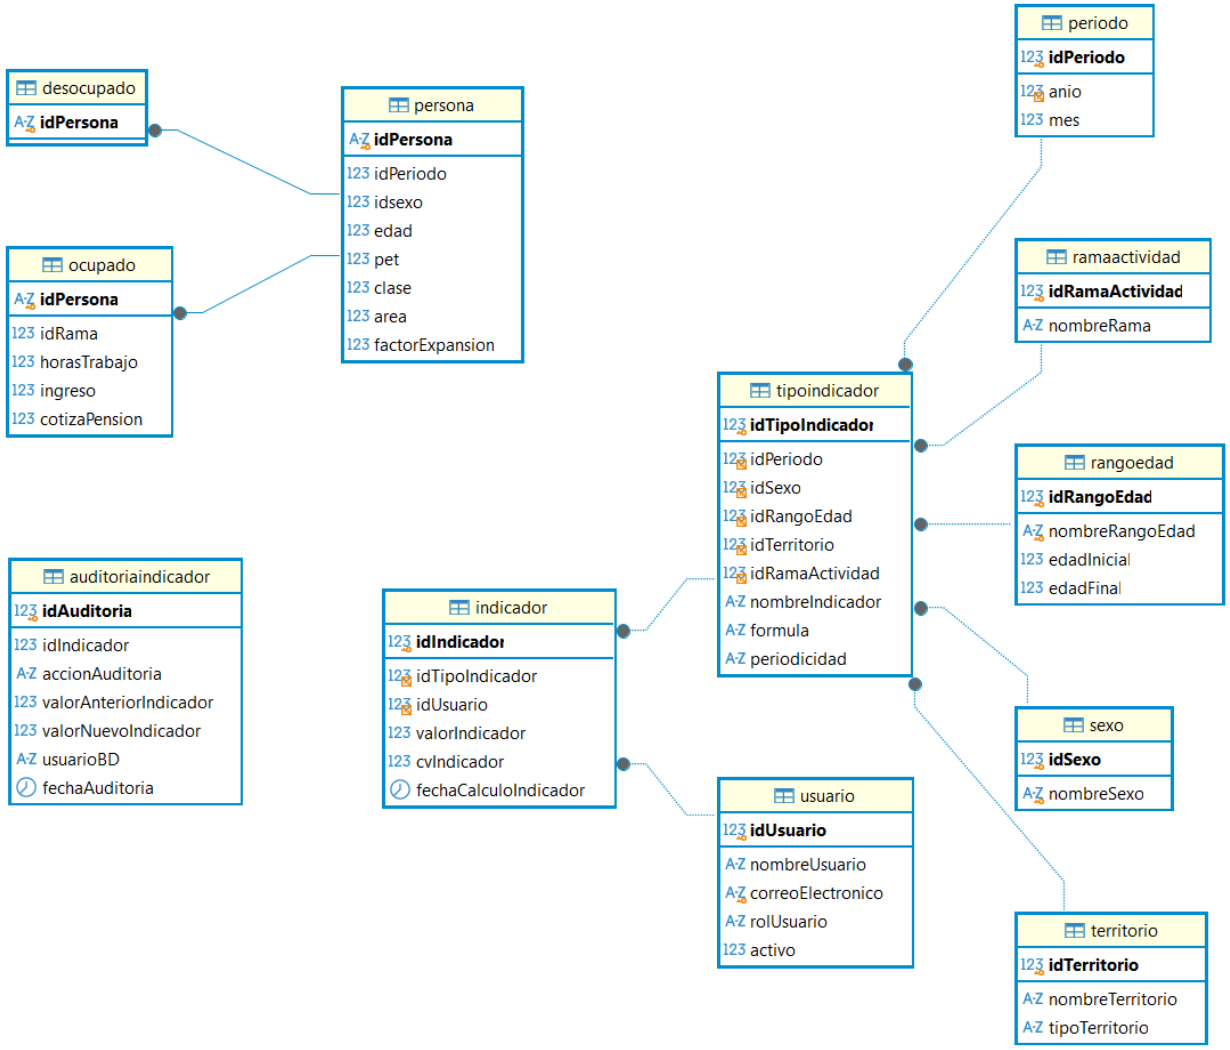
17. Modelado de base de datos relacional

17.1. Modelo lógico

Relación	Cardinalidad	Llave foránea
persona – ocupado	1 a 0..1	ocupado.idPersona → persona.idPersona
persona – desocupado	1 a 0..1	desocupado.idPersona → persona.idPersona
periodo – tipoIndicador	1 a N	tipoIndicador.idPeriodo → periodo.idPeriodo
sexo – tipoIndicador	0..1 a N	tipoIndicador.idSexo → sexo.idSexo
rangoEdad – tipoIndicador	0..1 a N	tipoIndicador.idRangoEdad → rangoEdad.idRangoEdad
territorio – tipoIndicador	0..1 a N	tipoIndicador.idTerritorio → territorio.idTerritorio
ramaActividad – tipoIndicador	0..1 a N	tipoIndicador.idRama → ramaActividad.idRama
tipoIndicador – indicador	1 a N	indicador.idTipoIndicador → tipoIndicador.idTipoIndicador
usuario – indicador	1 a N	indicador.idUsuario → usuario.idUsuario



17.2. Modelo físico



18. Diccionario de datos - El diccionario de datos se encuentra en la sección anterior

19. Implementación de la base de datos

La implementación de la base de datos, la creacion de tablas, las inserciones, los procedimientos, etc. se encuentran en el script de la carpeta de la segunda entrega del proyecto de ingenieria de datos.

19.1. Creación de tablas (DDL)

Dentro de la base de datos llamada proyecto_geih se crean las tablas de persona, ocupado, desocupado, indicador, tipoIndicador, usuario, periodo, ramaActividad, rangoEdad, sexo y territorio con las llaves primarias, foraneas y los constraints de acuerdo a la estructura definida.

19.2. Inserción de registros por tabla

En lo referente a la inserción de registros por tabla se detalla lo siguiente: Para el caso de las tablas persona, ocupado y desocupado, se cargó la información de enero a febrero de 2026 para realizar la respectiva prueba de funcionamiento del proyecto y para esto se realizo una preparación de los datos en un cuaderno de Python, en el cual se indica el año y el mes, el colab lee los tres archivos del DANE (características generales, ocupados y no ocupados) y a partir de ellos arma las tres tablas de la siguiente manera:

- **persona:** se construye el identificador idPersona (directorio + secuencia + orden, con ceros a la izquierda) y se seleccionan y renombran las variables: sexo, edad, clase, área y factor de expansión (FEX_C18). También se agrega el idPeriodo (por ejemplo, 202601).
- **ocupado:** se toman la rama de actividad (agrupando las divisiones CIIU de dos dígitos en 13 ramas), las horas trabajadas, el ingreso laboral y si cotiza a pensión (0 o 1).
- **desocupado:** se dejan las personas desocupadas (DSI = 1) de la base de no ocupados.

Antes de guardar se hacen verificaciones: identificadores o factores vacíos, repetidos, sexo, edad o clase fuera de rango, ocupados o desocupados que no estén en persona o sean menores de 15 años, y personas que aparezcan como ocupadas y desocupadas a la vez. Los registros que no pasan se separan en un archivo de rechazados y se deja un reporte con los conteos. Al final se escribe un CSV por tabla y por periodo (persona_202601.csv, etc.), en carpetas por año y mes, con los datos faltantes como \N para que SQL los lea como NULL

Para el caso de la tabla tipoIndicador, se insertó la información correspondiente al periodo, rama de actividad, rengo de edad, sexo y territorio para cada tipo de indicador. Finalmente, para el caso de usuario periodo, rama de actividad, rango de edad, sexo y territorio se subió la información que corresponde para cada uno de estos y no los 50 registros requeridos, salvo usuarios. Lo anterior se evidencia en la tabla sexo donde la encuesta solo contabiliza femenino o masculino.

Para la tabla de indicador se genera, primero, una vista que almacene por ejemplo si una persona está desocupada o ocupada, es decir realizar un join entre la tabla ocupado desocupado y persona. Luego, a partir de esta tabla se crean funciones para cada indicador,. es decir uno para tasa de ocupación, desocupación, pea, etc. Todo lo anterior teniendo en cuenta el factor de expansión de las personas. Y teniendo en cuenta estas funciones se crea un procedimiento almacenado que permite ejecutar las funciones cada vez que se carga un periodo nuevo a la base.

19.3. Consultas básicas y específicas por tabla

Primero se hace un select* de cada tabla. Después se escriben siete consultas por tabla, de una sola tabla, con filtros, agrupaciones y funciones de agregación. En las tablas con microdato las sumas usan el factor de expansión y se fija un periodo, porque cada base mensual representa la población completa.

19.4. Modificaciones y eliminaciones

Se hacen cinco modificaciones (UPDATE) y una eliminación (DELETE) sobre distintas tablas. Se ejecutan dentro de una transacción que termina en ROLLBACK, así los datos quedan intactos y la prueba se puede repetir.

19.5. Consultas multitabla

Se escriben consultas con JOIN entre las tablas (indicadores por periodo, territorio, sexo y rama, ocupados por rama, etc.) y subconsultas (valores por encima del promedio, personas que cumplen una condición en otra tabla, etc.), con al menos una o dos por tabla.

19.6. Procedimientos almacenados y vistas

Procedimientos: calcular un solo indicador, copiar las definiciones de un periodo a otro, verificar el microdato de un periodo e inactivar un usuario.

Vistas: detalle de indicadores con sus descripciones, indicadores vigentes, resumen laboral por periodo y ocupados por rama.

19.7. Triggers

Auditoría: al insertar, actualizar o borrar en indicador se guarda el registro en auditoriaIndicador (acción, valor anterior y nuevo, usuario de la base de datos y fecha).

Protección: se bloquea modificar o borrar la tabla de auditoría y el microdato (persona, ocupado, desocupado).

Validación: una persona no puede registrarse como ocupada y desocupada a la vez.

20. Referencias

Bakker, B. F. M., van Rooijen, J., y van Toor, L. (2014). The system of social statistical datasets of Statistics Netherlands: An integral approach to the production of register-based social statistics. Statistical Journal of the IAOS, 30(4), 411-424. https://doi.org/10.3233/SJI-140803

Departamento Administrativo Nacional de Estadística. (2024). Gran Encuesta Integrada de Hogares (GEIH): metodología general y ficha metodológica. DANE.

Otero-Cortés, A. (coord.), Acosta, K., Arango, L. E., Aristizábal, D., Ávila, O., Becerra, O., Fernández, C., Flórez, L. A., Galvis, L. A., Grajales, A., Granda, C., Hamann, F., Jaramillo, J., Medina, C., Morales, J., Morales, A., Morales, L., Ospina, J. J., Posso, C., Pulido, J. D., Ramos, M., y Sarasti, A. (2025). Nueva evidencia sobre la informalidad laboral y empresarial en Colombia. Ensayos sobre Política Económica (ESPE), 108. https://doi.org/10.32468/espe108